

Evaluación Comparativa de Arquitecturas de Deep Learning para Clasificación de Tumores Cerebrales en MRI

Sergio Danilo Hanco Mullisaca^{a,*}, Eduardo Joel Cuno Salazar^{a,*}, Mathias Alonso Barrios Medina^{a,*}, Miguel Angel Alvarez Choque^{a,*}

^a Universidad Nacional de San Agustín, Arequipa, Perú.

Abstract

Este estudio presenta una evaluación comparativa de cinco arquitecturas de deep learning: ResNet-50, EfficientNet-B0, ViT-B/16, Swin Transformer y CoAtNet, para la clasificación binaria de tumores cerebrales en imágenes de resonancia magnética. Se empleó un dataset público de 8764 imágenes, con partición estricta previa a cualquier aumento de datos para evitar data leakage. Cada modelo se evaluó en dos fases: base (30 épocas, tasa fija) y optimizada (early stopping, ReduceLROnPlateau, data augmentation). EfficientNet-B0 alcanzó 99.60 % de accuracy y 0.9998 de AUC-ROC con solo 4.0 M de parámetros, mientras que Swin-T obtuvo el AUC-ROC más alto (0.9999). ViT-B/16, pese a ser el modelo más grande (85.8 M), presentó el menor rendimiento debido a sobreajuste. Los resultados demuestran que las arquitecturas con sesgos convolucionales o atención local son más adecuadas para conjuntos de datos médicos de tamaño moderado.

Keywords: clasificación de tumores cerebrales, deep learning, EfficientNet, Swin Transformer, resonancia magnética

1. Introduccion

Las enfermedades neurológicas comprenden trastornos que afectan el sistema nervioso central y periférico, alterando funciones como el movimiento, la memoria, la cognición y la percepción, por lo que representan una de las principales causas de discapacidad y mortalidad en el mundo [1]. Su impacto ha aumentado en las últimas décadas debido al envejecimiento de la población y a diversos factores de riesgo, generando una mayor necesidad de métodos diagnósticos y terapéuticos más eficientes [1]. La diversidad de estas patologías, que incluye enfermedades neurodegenerativas, cerebrovasculares y funcionales, dificulta su diagnóstico por la complejidad y similitud de sus manifestaciones clínicas [2] [3].

Los tumores cerebrales son un conjunto diverso de neoplasias que pueden originarse en el cerebro o derivarse de metástasis de otros órganos, con distintos grados de malignidad y comportamiento clínico [4]. Entre ellos, el glioblastoma es el tumor cerebral primario maligno más frecuente y agresivo en adultos, debido a su crecimiento

infiltrativo, alta recurrencia y mal pronóstico, incluso con los tratamientos actuales [5]. Sus manifestaciones clínicas varían según la localización, el tamaño y la velocidad de crecimiento del tumor, siendo frecuentes las cefaleas persistentes, convulsiones, alteraciones cognitivas y déficits neurológicos que deterioran la calidad de vida [6] [7]. Además, la complejidad de su biología molecular y fisiopatología representa un reto para el diagnóstico y la elección del tratamiento más adecuado [7].

La resonancia magnética (MRI) es la principal técnica de neuroimagen para detectar y caracterizar tumores cerebrales, gracias a su alto contraste entre tejidos blandos y su capacidad para identificar la localización, extensión y características de la lesión [8]. Además, avances como la radiómica permiten extraer características cuantitativas de las imágenes, mejorando la clasificación tumoral, el pronóstico y la toma de decisiones clínicas mediante técnicas de inteligencia artificial [9]. Las técnicas modernas de neuroimagen también integran información anatómica, funcional y metabólica, favoreciendo una caracterización más completa de los tumores y una mejor planificación terapéutica [10]. En este contexto, la segmentación automática de imágenes de resonancia magnética se ha convertido en una etapa clave para delimitar la región tumoral y apoyar sistemas de diagnóstico basados en aprendizaje automático y aprendizaje profundo [11].

La resonancia magnética por imágenes (MRI) es una técnica de diagnóstico no invasiva que emplea campos magnéticos y ondas de radio para obtener imágenes detalladas de órganos y tejidos sin utilizar radiación ionizante [12][13]. Su alta resolución y contraste entre tejidos blandos la convierten

*Corresponding author.

Email addresses: shanccom@unsa.edu.pe (Sergio Danilo Hanco Mullisaca), ecunos@unsa.edu.pe (Eduardo Joel Cuno Salazar), mbarriosmed@unsa.edu.pe (Mathias Alonso Barrios Medina), malvarezcho@unsa.edu.pe (Miguel Angel Alvarez Choque)

URL: <https://orcid.org/0009-0002-6080-8661> (Sergio Danilo Hanco Mullisaca), <https://orcid.org/0009-0005-9736-404X> (Eduardo Joel Cuno Salazar), <https://orcid.org/0009-0003-6772-3035> (Mathias Alonso Barrios Medina), <https://orcid.org/0009-0003-9502-4493> (Miguel Angel Alvarez Choque)

en una herramienta esencial para evaluar enfermedades neurológicas, especialmente en la detección y caracterización de tumores cerebrales [12][14]. Además, los avances en adquisición y procesamiento de imágenes han mejorado su calidad diagnóstica y ampliado sus aplicaciones clínicas [15]. Por ello, la MRI es la base de numerosos sistemas de inteligencia artificial, al proporcionar imágenes de alta calidad que facilitan la detección y clasificación automática de anomalías cerebrales [15][14][13].

Un punto negativo es que la evaluación manual de imágenes es sumamente lenta y está sujeto a la fatiga visual de los radiólogos [16]. Además, la detección manual es propensa a errores de interpretación debido a las variaciones humanas. Los médicos deben analizar decenas de cortes transversales para emitir un diagnóstico preciso. Esta carga de trabajo retrasa el inicio de los tratamientos médicos vitales para los pacientes.

Identificar un tumor cerebral es complejo debido a su naturaleza morfológica. Los tumores cerebrales suelen presentar formas irregulares, bordes difusos y texturas muy similares al tejido sano. Asimismo, la presencia de ruido o artefactos técnicos en las resonancias dificulta la visibilidad de las anomalías [17]. Los métodos de análisis tradicionales fallan frecuentemente ante estas variaciones de iluminación y contraste. Estas deficiencias resaltan la necesidad clínica de implementar sistemas de asistencia automatizados y precisos.

La inteligencia artificial surge como una solución viable ante estas limitaciones clínicas. Los sistemas computacionales permiten procesar grandes volúmenes de imágenes en pocos segundos. Estas herramientas actúan como un soporte de segunda opinión para los radiólogos en los hospitales. El uso de algoritmos avanzados reduce significativamente la variabilidad en los diagnósticos médicos. Esta tecnología transforma la forma en que se abordan actualmente las patologías oncológicas [18].

El aprendizaje profundo ha demostrado un rendimiento superior en el reconocimiento de imágenes médicas. Las Redes Neuronales Convolucionales (CNN) representan el estándar de oro para estas tareas visuales complejas. Estos modelos matemáticos extraen características anatómicas de las resonancias de forma completamente automática [19]. Las CNN eliminan la necesidad de seleccionar manualmente las regiones de interés en la MRI. Su capacidad de análisis mejora la detección de anomalías estructurales en el cerebro.

Diversas investigaciones avalan la alta precisión de estas arquitecturas en entornos clínicos simulados [20]. Los modelos actuales logran diferenciar entre múltiples tipos de tumores cerebrales de manera eficiente. La aplicación de estas técnicas optimiza el tiempo de respuesta en la toma de decisiones médicas [21]. Sin embargo, la evaluación comparativa de diferentes arquitecturas bajo un mismo entorno sigue siendo necesaria. Es fundamental validar

el rendimiento de estos algoritmos utilizando conjuntos de datos públicos y actualizados.

Esta investigación tiene como objetivo comparar varios modelos de aprendizaje profundo para identificar tumores en imágenes de resonancia magnética. El estudio evalúa el rendimiento de diferentes arquitecturas convolucionales utilizando un dataset seleccionado de la plataforma Kaggle. El resto de este artículo científico se encuentra estructurado de forma secuencial. La sección dos describe los trabajos relacionados obtenidos mediante herramientas de inteligencia artificial. Los apartados posteriores detallan los materiales y métodos, los resultados experimentales, la discusión y las conclusiones finales.

2. Trabajos Relacionados

La variabilidad y la falta de estandarización en imágenes de Resonancia Magnética dificultan el diagnóstico automatizado y preciso de patologías cerebrales. El objetivo de este estudio fue evaluar el desempeño de múltiples arquitecturas preentrenadas mediante transferencia de conocimiento para la clasificación de cuatro clases de tumores. El aporte principal se basó en el análisis comparativo entre redes profundas como Xception, ResNet50, VGG16 y DenseNet121. La metodología implementó el uso de un dataset público de Kaggle con 7023 imágenes MRI para el entrenamiento y ajuste fino de los hiperparámetros. Como resultado principal, el modelo Xception alcanzó una precisión del 98.73 %. Sin embargo, la deficiencia radica en una menor respuesta para las clases glioma y meningioma, [22].

La baja resolución y los artefactos visuales en las resonancias magnéticas reducen la tasa de detección temprana de tumores. Los autores de este estudio buscaron optimizar el proceso de clasificación mediante el ajuste fino secuencial para la familia de redes EfficientNet. El aporte del trabajo se basó en la explotación de los coeficientes de escalamiento de EfficientNetB0-B4 para capturar características sutiles en los tejidos. La metodología incluyó el procesamiento del dataset público de Figshare y un pipeline de entrenamiento con optimizadores avanzados para evitar el sobreajuste. Logrando un 99.06 % de precisión, 98.73 % de precisión, 99.13 % de recall y un F1-score de 98.79 %. La deficiencia fue la ausencia de un conjunto de pruebas con validación externa en un entorno clínico real [23].

El alto costo computacional y la pérdida de características globales limitan la efectividad de las redes neuronales individuales en la clasificación multiclase de tumores. El objetivo de este estudio fue desarrollar un sistema de clasificación híbrido que combinara las ventajas de múltiples extractores de características profundas. El aporte se basó en el diseño de un ensamble que integra las capas de ResNet50V2, MobileNetV2 y DenseNet121. La metodología consistió en fusionar los vectores de características extraídos de 7023 imágenes de un repositorio público antes de la capa de

clasificación final. El modelo compuesto obtuvo una precisión del 98.75 %, con métricas simétricas de 98.76 % en precision y 98.75 % en F1-score. La deficiencia fue el uso exclusivo de datos públicos preprocesados, omitiendo el impacto que el ruido clínico y los outliers causan en sistemas híbridos [24].

Las variaciones morfológicas complejas en las imágenes de resonancia magnética limitan la capacidad de las redes convolucionales estándar para discriminar entre múltiples etapas de masas tumorales. El objetivo de la investigación fue optimizar el proceso de clasificación multiclase mediante el ajuste fino secuencial de la arquitectura ResNet50 enriquecida con capas densas adicionales. El aporte del estudio se basó en el diseño de un bloque de clasificación personalizado que maximiza la retención de características jerárquicas preentrenadas. La metodología requirió la consolidación y procesamiento de tres bases de datos públicas: SARTAJ, Br35H y Figshare. Como resultado, el modelo modificado alcanzó una precisión sobresaliente del 99.31 %, demostrando mejoras paralelas en las métricas de F1-score, precision, recall y el área bajo la curva (AUC). La deficiencia identificada es que el rendimiento del clasificador no fue contrastado ni respaldado mediante una validación externa clínica [25].

La incapacidad intrínseca de las operaciones convolucionales locales para modelar dependencias espaciales de largo alcance reduce la precisión en la identificación de bordes tumorales difusos. Los autores buscaron evaluar el potencial de los mecanismos de autoatención global mediante el uso adaptativo del modelo preentrenado Vision Transformer ViT-B/16. El aporte principal se basó en la explotación del procesamiento por parches de imagen (patch embedding) para capturar relaciones contextuales complejas en cortes cerebrales. La metodología consistió en realizar un fine-tuning integral sobre un dataset público de imágenes por resonancia magnética estructurado en cuatro categorías patológicas. El experimento reportó una precisión máxima del 99.24 % en el conjunto de prueba para la variante ViT-B/16. La brecha metodológica detectada radica en que la investigación no detalla el uso de una cohorte externa [26].

El elevado costo computacional y el requerimiento masivo de datos de los Transformers estándar limitan su viabilidad práctica en entornos de diagnóstico médico automatizado. El objetivo del estudio fue realizar una comparación directa entre las capacidades de procesamiento del Vision Transformer convencional y la arquitectura de ventanas desplazables Swin Transformer. El aporte se centró en demostrar la eficiencia del Swin Transformer para procesar información a múltiples escalas espaciales con una complejidad lineal. La metodología implementó el entrenamiento jerárquico de ambos enfoques utilizando un repositorio público indexado en Kaggle con un total de 3000 imágenes MRI. Los resultados estadísticos confirmaron la superioridad del modelo Swin al alcanzar un 98.71 % de precisión

frente al 95.30 % obtenido por la arquitectura ViT. Como deficiencia, el estudio se limitó a un dataset moderado [27].

La pérdida de detalles de alta frecuencia debido al escalamiento global de los Transformers perjudica la delimitación de anomalías de tamaño milimétrico. El objetivo del trabajo fue integrar las capacidades locales de las redes convolucionales con el modelado de dependencias globales propio de los bloques Transformer en una estructura unificada. El aporte consistió en el desarrollo del modelo híbrido TECNN, el cual actúa de forma funcionalmente equivalente a una arquitectura CvT (Convolutional Vision Transformer). La metodología validó robustamente el pipeline computacional utilizando dos plataformas de acceso público de manera independiente: BraTS 2018 y Figshare. El sistema reportó una precisión del 96.75 % sobre el exigente benchmark de BraTS 2018 y un 99.10 % en la base de datos Figshare. Su deficiencia es que el marco de trabajo no emplea la arquitectura CvT nominal de referencia, sino una aproximación híbrida propia [28].

La degradación de gradientes en redes profundas dificulta la extracción simultánea de texturas locales y patrones contextuales abstractos. El objetivo del estudio fue diseñar un marco de aprendizaje simétrico de dos ramas paralelas que combine módulos de Transformer con redes residuales optimizadas. El aporte se basó en el acoplamiento de un módulo de autoatención (Self-Attention) junto a una arquitectura iResNet modificada para estabilizar el flujo de información. La metodología requirió el análisis de 3064 cortes (slices) de resonancias magnéticas del repositorio Figshare, distribuidos en cuatro clases diagnósticas. Las pruebas de evaluación demostraron que el extractor basado en iResNet alcanzó una precisión del 99.30 %, mejorando la capacidad de generalización en un 20 % de imágenes no vistas previamente durante el ajuste. La deficiencia es la falta de validación del algoritmo frente a una cohorte clínica externa real [29].

La desconexión algorítmica entre los sistemas de segmentación y clasificación obliga a los centros de salud a implementar pipelines computacionales duplicados y costosos. El objetivo de la investigación fue unificar ambas tareas en un único marco de aprendizaje optimizado para datos médicos. El aporte principal se basó en el diseño de un Adaptive Masked Transformer capaz de resolver problemas multitarea simultáneamente. La metodología empleó 485 casos clínicos privados junto con un conjunto de datos independiente para la validación externa del sistema. El modelo obtuvo un Dice de 0.91 y una precisión de clasificación del 93.4 %. La deficiencia del enfoque es que la precisión final de la clasificación quedó significativamente por debajo de los modelos especializados dedicados a etiquetado [30].

La presencia de ruido de alta frecuencia y la variabilidad de contraste en los escáneres de diferentes fabricantes degradan el rendimiento de las redes U-Net convencionales. El objetivo del estudio fue estructurar un pipeline secuen-

cial que unificara el filtrado de ruido, la segmentación y la posterior clasificación jerárquica de gliomas. El aporte se basó en un flujo de trabajo integrado que conecta una red U-Net con clasificadores basados en VGG y GoogLeNet. La metodología validó el pipeline sobre el conjunto de datos BraTS2019, ejecutando pruebas de segmentación y clasificación en etapas consecutivas. Los resultados alcanzaron un Dice de 0.82/0.91/0.72 para las subtarefas de segmentación y un 97.44 % de precisión en la clasificación. La deficiencia del trabajo es que el modelo requiere mejoras en su arquitectura base debido a la falta de originalidad en los bloques de conexión [31].

Al analizar la literatura científica actual, se identifican dos brechas metodológicas fundamentales. En primer lugar, la gran mayoría de las investigaciones previas enfocadas en datasets públicos de Kaggle o Figshare [22, 23, 24, 25, 26, 27] cometen el error técnico de aplicar algoritmos de aumentación de datos de manera global sobre todo el conjunto de imágenes antes de realizar la división. Esta práctica genera un fenómeno severo de Data Leakage, donde variantes modificadas de la misma imagen original terminan distribuidas simultáneamente en los grupos de entrenamiento, validación y prueba, inflando artificialmente las métricas de rendimiento y reduciendo la capacidad real de generalización.

En segundo lugar, la mayoría de los trabajos previos abordan el problema como una clasificación multiclase (glioma, meningioma, pituitario, sin tumor). Si bien esta granularidad diagnóstica es valiosa, introduce una complejidad adicional que dificulta la evaluación controlada de pipelines de preprocesamiento y particionamiento. Por esta razón, el presente trabajo adopta un enfoque de clasificación binaria (yes/no tumor), para lo cual se tomó un subconjunto aleatorio del 20 % de los datos originales y se reestructuró explícitamente en dos clases: yes (con tumor, combinando gliomas, meningiomas y demás variantes) y no (cerebro sano, sin tumor). Esta simplificación permite aislar y evaluar con mayor rigor el impacto de las decisiones metodológicas sobre el preprocesamiento de datos, minimizando las variables de confusión asociadas a la granularidad multiclase.

Asimismo, se observa una falta de protocolos automatizados para la detección y depuración de anomalías visuales u outliers antes del entrenamiento. El presente trabajo aborda directamente estas deficiencias implementando un pipeline de automatización estricto (Data Automation Split) donde el particionamiento en tres grupos independientes (Train, Validation y Test) se ejecuta de manera prioritaria y absoluta antes de cualquier técnica de expansión sintética de datos. Adicionalmente, se introduce el uso de algoritmos avanzados de detección de anomalías (Outliers) para asegurar la pureza del conjunto de datos y garantizar la robustez clínica del modelo propuesto.

A continuación, se presenta la Tabla 1, la cual sintetiza

los aportes, resultados y deficiencias metodológicas de las investigaciones analizadas en esta sección.

Table 1: Tabla comparativa de la literatura científica analizada para la detección y segmentación de tumores cerebrales.

Autor y Año	Modelo / Aporte Principal	Resultados Clave	Deficiencia o Brecha Identificada
[22]	Transfer Learning (Xception, ResNet50, VGG16)	Accuracy: 98.73 %, F1: 95.29 %	Menor recall en glioma; explicabilidad y diversidad de datos limitadas.
[23]	EfficientNetB0-B4 fine-tuned en CE-MRI	Accuracy: 99.06 %, F1: 98.79 %	Ausencia total de validación externa en entornos clínicos reales.
[24]	Ensamble híbrido (ResNet50V2 + MobileNetV2 + DenseNet121)	Accuracy: 98.75 %, F1: 98.75 %	Dependencia de datasets públicos compuestos; sensible a ruido y outliers.
[25]	Fine-tuning de ResNet50 + Capas adicionales	Accuracy: 99.31 %, Alto AUC	No reporta validación externa con muestras de origen clínico real.
[26]	Vision Transformer (ViT-B/16) fine-tuned	Accuracy: 99.24 %	Falta de descripción de cohortes externas y validación multicéntrica.
[27]	Comparación ViT vs. Swin Transformer	Swin Acc: 98.71 %, ViT Acc: 95.30 %	Dataset de escala moderada y ausencia de esquemas de validación externa.
[28]	TECNN híbrido (Convolución + Transformer)	Acc BraTS: 96.75 %, Figshare: 99.10 %	No emplea CvT nominal; es un desarrollo híbrido propio ad-hoc.
[29]	Dos ramas (iResNet + Self-Attention Module)	Accuracy: 99.30 %, Gen. +20 %	Evaluado solo en bases públicas; sin reporte de cohorte clínica externa.
[30]	Multitarea con Adaptive Masked Transformer	IoU: 0.921, Clasificación Acc: 93.4 %	La precisión de clasificación queda por debajo de los modelos monoproósito.
[31]	Pipeline integrado UNet + VGG/GoogLeNet	Segmentación Dice: 0.82; Clasificación Acc: 97.44 %	Falta de originalidad en la arquitectura base; requiere optimización estructural.

3. Materiales y Metodos

3.1. Fundamentos teóricos

La Inteligencia Artificial (IA) es un campo de la informática orientado al desarrollo de sistemas capaces de percibir su entorno, razonar y ejecutar acciones para alcanzar objetivos específicos de manera inteligente [32]. El Machine Learning (ML) constituye un subcampo de la IA que permite a los sistemas aprender a partir de datos y mejorar su desempeño sin ser programados explícitamente para cada tarea [32]. Aunque ambos conceptos suelen utilizarse como sinónimos, la IA engloba diferentes enfoques para construir sistemas inteligentes, mientras que el Machine Learning se centra en el aprendizaje basado en la experiencia y los datos [32]. Esta relación convierte al aprendizaje automático en uno de los principales métodos para desarrollar aplicaciones modernas de inteligencia artificial [32].

El Deep Learning o aprendizaje profundo es una rama especializada del Machine Learning que utiliza redes neuronales artificiales con múltiples capas para aprender representaciones complejas de los datos [33]. A diferencia de los métodos tradicionales, este enfoque extrae automáticamente las características más relevantes sin requerir una ingeniería manual de atributos [33]. Gracias a esta capacidad, el aprendizaje profundo se emplea en tareas como clasificación de imágenes, reconocimiento de voz,

procesamiento del lenguaje natural y visión por computadora [33]. Su alto rendimiento y capacidad para procesar grandes volúmenes de datos han convertido al Deep Learning en una de las tecnologías más importantes de la inteligencia artificial actual [33].

El reconocimiento y clasificación de imágenes médicas consiste en identificar estructuras anatómicas, tejidos o anomalías presentes en imágenes obtenidas mediante técnicas de diagnóstico como resonancia magnética, tomografía computarizada y radiografías [34]. Para ello, los algoritmos de aprendizaje profundo analizan automáticamente las imágenes y extraen características relevantes que permiten asignar una categoría diagnóstica [34]. Este proceso facilita la detección de enfermedades, la diferenciación entre tejidos normales y patológicos, y el apoyo a la toma de decisiones clínicas [34]. Debido a su precisión y capacidad para analizar grandes volúmenes de datos visuales, esta técnica constituye una herramienta fundamental en la medicina asistida por inteligencia artificial [34].

Las Redes Neuronales Convolucionales (CNN) son arquitecturas de aprendizaje profundo diseñadas para procesar información con estructura espacial, especialmente imágenes [35]. Estas redes extraen automáticamente características mediante capas de convolución, agrupamiento (pooling) y funciones de activación, aprendiendo patrones desde niveles simples hasta representaciones complejas [35].

Gracias a este mecanismo, las CNN se utilizan en tareas como clasificación, detección y segmentación de imágenes [35]. Su capacidad para aprender características visuales de forma automática las ha convertido en una de las arquitecturas más utilizadas en aplicaciones de visión por computadora e imágenes médicas [35].

Los Vision Transformers (ViT) son arquitecturas de aprendizaje profundo que adaptan el mecanismo de autoatención (self-attention) de los Transformers al procesamiento de imágenes [36]. Estos modelos dividen una imagen en pequeños parches que son procesados como secuencias para capturar relaciones tanto locales como globales [36]. Gracias a este enfoque, los Vision Transformers se emplean en tareas como clasificación, detección y segmentación de imágenes [36]. Su capacidad para modelar dependencias de largo alcance los ha convertido en una alternativa competitiva frente a las redes neuronales convolucionales en aplicaciones de visión por computadora [36].

Los modelos híbridos CNN-Transformer son arquitecturas que combinan las capacidades de las redes neuronales convolucionales y los Vision Transformers para el análisis de imágenes [37]. Estos modelos aprovechan las CNN para extraer características locales y los Transformers para capturar relaciones globales mediante mecanismos de autoatención [37]. Como resultado, generan representaciones más completas que mejoran el desempeño en tareas de clasificación, detección y segmentación de imágenes [37]. Debido a este equilibrio entre precisión y capacidad de representación, los modelos híbridos constituyen una alternativa prometedora para aplicaciones de visión por computadora e imágenes médicas [37].

El Transfer Learning o aprendizaje por transferencia es una técnica que reutiliza modelos previamente entrenados para resolver nuevas tareas con una cantidad limitada de datos [38]. Este enfoque aprovecha el conocimiento adquirido por modelos profundos para reducir el tiempo de entrenamiento y mejorar el rendimiento en nuevas aplicaciones [38]. Además, suele combinarse con técnicas como el aumento de datos (data augmentation) y el ajuste fino (fine-tuning) para incrementar la capacidad de generalización del modelo [38]. Gracias a estas ventajas, el aprendizaje por transferencia es ampliamente utilizado en sistemas de análisis y clasificación de imágenes médicas basados en inteligencia artificial [38].

Las métricas de evaluación son medidas cuantitativas empleadas para determinar el desempeño y la capacidad de generalización de un modelo de aprendizaje automático [39]. La selección de una métrica depende del problema de clasificación y de los objetivos específicos de la aplicación [39]. Entre las métricas más utilizadas se encuentran la exactitud (accuracy), la precisión (precision), la sensibilidad (recall), la puntuación F1 y el área bajo la curva ROC (AUC), ya que cada una evalúa un aspecto diferente del rendimiento del modelo [39]. El uso conjunto de estas métricas permite realizar una evaluación más completa y

confiable del comportamiento de un sistema de aprendizaje automático [39].

La comparación de arquitecturas de Deep Learning para clasificación de imágenes médicas consiste en analizar el desempeño de diferentes modelos para determinar cuál se adapta mejor a una tarea específica [40]. Este proceso evalúa aspectos como la precisión, la eficiencia y la capacidad de generalización de arquitecturas basadas en Redes Neuronales Convolucionales y Vision Transformers [40]. La comparación permite identificar las fortalezas y limitaciones de cada modelo según las características del conjunto de datos y del problema de clasificación [40]. Estos análisis constituyen una etapa fundamental para seleccionar la arquitectura más adecuada en el desarrollo de sistemas de diagnóstico asistido mediante inteligencia artificial [40].

3.2. Herramientas y Tecnologías

El desarrollo del sistema se realizará utilizando Python 3.11 como lenguaje de programación principal, debido a su amplio ecosistema de bibliotecas orientadas al aprendizaje automático y al aprendizaje profundo. De acuerdo con Rana y Bhushan [41], Python constituye el lenguaje predominante para el desarrollo de aplicaciones de inteligencia artificial en el análisis de imágenes médicas. Asimismo, se empleará Google Colab como entorno de ejecución en la nube, ya que proporciona acceso a GPU y facilita la experimentación reproducible sin necesidad de infraestructura local de alto rendimiento. Puttagunta y Ravi [42] destacan que la configuración del entorno de hardware y software es fundamental para garantizar la reproducibilidad de los experimentos.

Para la implementación de los modelos se utilizarán TensorFlow 2.18.0 y Keras 3.8.0 para las arquitecturas CNN como ResNet50 y EfficientNet-B0, mientras que los modelos basados en Transformers (ViT-B/16, Swin Transformer y CoAtNet) serán implementados con PyTorch 2.6 y timm 1.0. Beirović et al. [43] presentan una comparativa de estos frameworks para clasificación de imágenes médicas. El preprocesamiento de las imágenes se realizará con OpenCV 4.10, NumPy 2.2 para operaciones matriciales, scikit-learn 1.6 para métricas y partición de datos, y Matplotlib 3.10 para visualización. Laçi et al. [44] señalan que TensorFlow, Keras y PyTorch son los frameworks más utilizados en Deep Learning para imágenes médicas.

3.3. Dataset

Para el desarrollo del presente proyecto se empleará el dataset *Brain Tumor MRI Datasets*, publicado por Shashin en Kaggle [45]. Dicho dataset contiene 8764 imágenes de resonancia magnética (MRI) del cerebro organizadas para un problema de clasificación binaria.

Las imágenes se encuentran clasificadas en dos categorías: Yes (pacientes con presencia de tumor cerebral) y No (pacientes sin evidencia de tumor cerebral).




Figure 1: Ejemplo de imagen perteneciente a la categoría "Yes".




Figure 2: Ejemplo de imagen perteneciente a la categoría "No".

Asimismo, el conjunto de datos se encuentra dividido en un 80 % para entrenamiento y un 20 % para pruebas, lo que facilita el desarrollo y la evaluación de modelos de aprendizaje profundo. Debido a que se trata de un conjunto de imágenes, el dataset no presenta atributos tabulares convencionales; cada registro está conformado por una imagen de resonancia magnética y su correspondiente etiqueta de clasificación.

Table 2: Descripción de las variables del dataset.

Variable	Descripción
Imagen MRI	Imagen de resonancia magnética cerebral.
Clase	Etiqueta de la imagen ("Yes" o "No").
Train/Test	Indica si la imagen pertenece al conjunto de entrenamiento o de prueba.

El conjunto de datos está organizado en dos subconjuntos: entrenamiento y prueba. La distribución de imágenes por

clase se muestra en la Tabla 3.

Table 3: Distribución de imágenes por clase y conjunto.

Conjunto	No Tumor	Tumor	Total
Train	2869	4143	7012
Test	717	1035	1752
Total	3586	5178	8764

Con el propósito de conocer la distribución de las imágenes, se realizó un análisis considerando la cantidad de muestras por clase y por conjunto de datos.




Figure 3: Distribución total de imágenes por clase.

Como se observa en la Figura 3, el conjunto de datos presenta 5178 imágenes con tumor (59.1 %) y 3586 imágenes sin tumor (40.9 %). Esto evidencia un ligero desbalance entre ambas clases, aunque la diferencia no es lo suficientemente grande como para impedir el entrenamiento del modelo.




Figure 4: Distribución de imágenes por conjunto de entrenamiento y prueba.

La Figura 4 muestra que la distribución de imágenes se mantiene tanto en el conjunto de entrenamiento como en el de prueba. En ambos casos, la clase Tumor posee una mayor cantidad de muestras que la clase No Tumor, conservando una proporción similar entre los dos subconjuntos.




Figure 5: Distribución porcentual de las clases del dataset.

La Figura 5 muestra la distribución porcentual de las imágenes del dataset. Se observa que el 59.1% corresponde a imágenes con presencia de tumor cerebral, mientras que el 40.9% pertenece a imágenes sin tumor. Esta diferencia evidencia un ligero desbalance entre las clases, el cual debe considerarse durante el entrenamiento del modelo.

3.4. Metodología propuesta

Antes de la carga tensorial, las imágenes del repositorio se someterán a una verificación estricta de formato e integridad mediante la biblioteca PIL. El algoritmo filtra de manera automática cualquier archivo corrupto o con extensiones distintas a .jpg, .jpeg y .png. Posteriormente, los tensores de entrada se redimensionan al tamaño estándar de la arquitectura de destino mediante torchvision. Finalmente, las matrices de píxeles se convierten al rango flotante de 0 a 1 y se estandarizan por canal utilizando la media (0.485, 0.456, 0.406) y desviación estándar (0.229, 0.224, 0.225) del conjunto ImageNet.

El particionamiento del conjunto de datos en las carpetas train, val y test se respeta de manera prioritaria y estricta desde el sistema de archivos. Esta separación física se ejecuta de forma previa a cualquier operación de transformación o carga en memoria. Los subconjuntos de validación y prueba emplean únicamente una transformación de evaluación determinista sin distorsiones estocásticas. Con este diseño metodológico riguroso se elimina completamente la posibilidad de fuga de datos durante el entrenamiento.

El proceso de expansión sintética de datos se aplica exclusivamente al conjunto de entrenamiento durante el flujo de trabajo optimizado. Las transformaciones de aumento en PyTorch incluyen giros horizontales aleatorios y rotaciones espaciales en un rango de $\pm 10^\circ$. Asimismo, se incorporan perturbaciones fotométricas dinámicas en el espacio cromático mediante ColorJitter con variaciones de 0.1 en brillo y contraste. Estas modificaciones en tiempo de ejecución incrementan la invariancia de la red ante artefactos visuales sin alterar la pureza del conjunto de test.

El pipeline computacional se ejecuta utilizando la función de pérdida CrossEntropyLoss y el optimizador Adam sobre la GPU de Google Colab. En la Fase 2 optimizada, se

implementa precisión mixta automática (AMP con GradScaler) para acelerar el tiempo de cómputo. El ajuste de hiperparámetros se controla dinámicamente mediante el programador ReduceLROnPlateau y decaimiento de pesos. Finalmente, se activa un stopper de convergencia basado en Early Stopping sobre el val_loss para preservar automáticamente los pesos del mejor modelo.

4. Resultados

4.1. ResNet50

Entrenamiento desde cero (scratch + normalizado):. ResNet50 fue entrenado desde cero con el pipeline de normalización estricta (CenterCrop cuadrado, ecualización de histograma, RGB forzado) durante 30 épocas con tasa de aprendizaje fija de 1×10^{-4} , sin data augmentation ni early stopping. Las métricas obtenidas sobre el conjunto de prueba se presentan en la Tabla 4.

Table 4: Métricas de ResNet50 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	97.48%
Balanced Accuracy	96.93%
Precisión	98.56%
Recall (Sensibilidad)	98.05%
Especificidad	95.82%
F1-Score	98.31%
MCC	0.9341
AUC-ROC	0.9980

La arquitectura residual de 23.5M de parámetros alcanzó una convergencia estable sin signos de sobreajuste. La pérdida de entrenamiento y validación se mantuvieron cercanas durante todo el entrenamiento, con el mejor modelo preservado en la época 20 (val_loss de 0.0553). Las curvas de aprendizaje muestran un descenso paralelo de train_loss y val_loss, confirmando que las conexiones residuales facilitan un aprendizaje efectivo incluso sin pesos preentrenados.




Figure 6: Curvas de aprendizaje de ResNet50 desde cero con pipeline normalizado.

4.2. EfficientNet-B0

Entrenamiento desde cero (scratch + normalizado):. EfficientNet-B0, la arquitectura más compacta del estudio con solo

4.0M de parámetros, fue entrenada desde cero con el pipeline de normalización estricta durante 30 épocas con tasa de aprendizaje fija de 1×10^{-4} . Las métricas obtenidas se presentan en la Tabla 5.

Table 5: Métricas de EfficientNet-B0 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	97.00%
Balanced Accuracy	96.36%
Precisión	98.30%
Recall (Sensibilidad)	97.66%
Especificidad	95.06%
F1-Score	97.98%
MCC	0.9215
AUC-ROC	0.9919

A pesar de contar con 95% menos parámetros que ViT-B/16, EfficientNet-B0 supera al transformer puro en 1.26 puntos porcentuales de accuracy. El modelo convergió rápidamente gracias a su compound scaling, alcanzando el mejor val-loss de 0.0682 en la época 10. Las curvas de aprendizaje muestran un entrenamiento saludable sin divergencia significativa entre train y validación. Con solo 55.28 ms de inferencia por batch, EfficientNet-B0 es el modelo más rápido del estudio, posicionándose como la opción más eficiente para entornos con recursos computacionales limitados.




Figure 7: Curvas de aprendizaje de EfficientNet-B0 desde cero con pipeline normalizado.

4.3. ViT-B/16

Entrenamiento desde cero (scratch + normalizado):. ViT-B/16, el modelo con mayor capacidad del estudio (85.8M de parámetros), fue entrenado desde cero con el pipeline de normalización estricta durante 30 épocas con tasa de aprendizaje fija de 1×10^{-4} . Las métricas obtenidas se presentan en la Tabla 6.

Table 6: Métricas de ViT-B/16 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	95.74%
Balanced Accuracy	95.53%
Precisión	97.38%
Recall (Sensibilidad)	95.84%
Especificidad	95.22%
F1-Score	96.61%
MCC	0.8916
AUC-ROC	0.9892

ViT-B/16 obtuvo el accuracy más bajo del estudio (95.74%), a pesar de triplicar en parámetros a Swin-T y tener 21 veces más parámetros que EfficientNet-B0. La ausencia de sesgos inductivos convolucionales obliga al modelo a aprender desde cero todas las relaciones espaciales, lo que resulta ineficiente con un dataset de solo 6893 imágenes. El entrenamiento, sin embargo, fue saludable: las curvas de aprendizaje (Figura 8) muestran convergencia paralela entre train y validación, sin la divergencia característica del sobreajuste observado en configuraciones con transfer learning.




Figure 8: Curvas de aprendizaje de ViT-B/16 desde cero con pipeline normalizado.

4.4. Swin Transformer

Entrenamiento desde cero (scratch + normalizado):. Swin-T fue entrenado desde cero con el pipeline de normalización estricta durante 30 épocas con tasa de aprendizaje inicial de 1×10^{-4} , reducida por ReduceLROnPlateau en las épocas finales. Las métricas obtenidas se presentan en la Tabla 7.

Table 7: Métricas de Swin-T entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	96.32%
Balanced Accuracy	96.53%
Precisión	98.93%
Recall (Sensibilidad)	96.10%
Especificidad	96.96%
F1-Score	97.50%
MCC	0.9070
AUC-ROC	0.9955

Swin-T superó a ViT-B/16 por 0.58 puntos porcentuales (96.32% vs. 95.74%) con 68% menos parámetros (27.5M vs. 85.8M). El mecanismo de atención local por ventanas desplazadas (7×7) demostró ser más eficiente que la atención global de ViT-B/16, permitiendo al modelo concentrarse en regiones anatómicas locales relevantes. Las curvas de aprendizaje (Figura 9) confirman un entrenamiento estable sin sobreajuste, con el mejor modelo registrado en la época 29 (val_loss de 0.0583).




Figure 9: Curvas de aprendizaje de Swin-T desde cero con pipeline normalizado.

4.5. CoAtNet

Entrenamiento desde cero (scratch + normalizado):. CoAtNet, el modelo híbrido que combina capas convolucionales MBConv con bloques de atención Transformer, fue entrenado desde cero con el pipeline de normalización estricta durante 30 épocas. Las métricas obtenidas se presentan en la Tabla 8.

Table 8: Métricas de CoAtNet entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	98.35%
Balanced Accuracy	98.27%
Precisión	99.34%
Recall (Sensibilidad)	98.44%
Especificidad	98.10%
F1-Score	98.89%
MCC	0.9572
AUC-ROC	0.9952

CoAtNet obtuvo el mejor desempeño del estudio con 98.35% de accuracy, superando a ViT-B/16 por 2.61 puntos porcentuales con 69% menos parámetros (26.7M vs. 85.8M). La combinación de convoluciones iniciales —que proveen sesgo inductivo de localidad— con atención global en etapas profundas resultó en el equilibrio óptimo entre capacidad de representación y eficiencia. Las curvas de aprendizaje muestran una convergencia excepcionalmente rápida: en la época 3 el modelo ya alcanzaba 96.62% de accuracy en validación. El entrenamiento fue el más estable de todos los modelos evaluados, con una brecha train/val de solo 0.0000 en la mejor época (época 14, val_loss de 0.0389), evidenciando ausencia total de sobreajuste.




Figure 10: Curvas de aprendizaje de CoAtNet desde cero con pipeline normalizado.

4.6. Analisis Comparativo

La Tabla 9 presenta la comparacion directa de las cinco arquitecturas evaluadas. Todos los modelos fueron entrenados desde cero (sin pesos preentrenados de ImageNet) con el pipeline de normalizacion estricta (CenterCrop cuadrado, conversion RGB forzada y ecualizacion de histograma), lo que garantiza una comparacion justa al eliminar los artefactos estadisticos del dataset identificados durante el estudio.

CoAtNet obtuvo el mejor desempeño global con 98.35% de accuracy, un MCC de 0.9572 y solo 26.7M de parámetros, beneficiándose de la combinacion de capas convolucionales y atencion Transformer. ResNet50 (97.48%) y EfficientNet-B0 (97.00%) demostraron que las arquitecturas puramente convolucionales ofrecen un rendimiento solido incluso desde cero, con la ventaja adicional de una inferencia rapida (101.9 ms y 55.3 ms por batch respectivamente). Swin-T (96.32%) supero a ViT-B/16 (95.74%) gracias a su mecanismo de atencion local por ventanas, confirmando que restringir la atencion a regiones anatomicamente relevantes es mas eficiente que la atencion global. ViT-B/16, pese a ser el modelo mas grande del estudio (85.8M de parámetros), obtuvo el rendimiento mas bajo, evidenciando que la capacidad bruta de parámetros no compensa la ausencia de sesgos inductivos en regimenes de datos limitados.

Table 9: Comparacion de resultados. Todos los modelos entrenados desde cero con pipeline de normalizacion estricta (scratch + normalizado).

Metrica	ResNet50	ENet-B0	ViT-B/16	Swin-T	CoAtNet
Accuracy (%)	97.48	97.00	95.74	96.32	98.35
F1-Score (%)	98.31	97.98	96.61	97.50	98.89
MCC	0.9341	0.9215	0.8916	0.9070	0.9572
AUC-ROC	0.9980	0.9919	0.9892	0.9955	0.9952
Parametros (M)	23.5	4.0	85.8	27.5	26.7
Inferencia (ms)	101.9	55.3	205.5	118.6	137.2

En terminos de eficiencia computacional, EfficientNet-B0 destaca con solo 55.3 ms de inferencia y 4.0M de parametros, siendo 3.7 veces mas rapido que ViT-B/16 con el 4.7% de sus parametros. CoAtNet ofrece el mejor equilibrio entre precision y eficiencia: supera a ResNet50 en accuracy (+0.87 pp) con apenas 3.2M de parametros adicionales. ViT-B/16, con 85.8M de parametros, es el modelo mas lento (205.5 ms) y el menos preciso, confirmando que las arquitecturas con sesgos convolucionales o mecanismos de atencion local son mas adecuadas para la clasificacion de tumores cerebrales en conjuntos de datos de tamano moderado.

4.7. Analisis de Artefactos del Dataset

Un hallazgo relevante de este estudio fue la identificacion de artefactos sistematicos en el dataset original que inflaban artificialmente las metricas. Las imagenes de la clase “yes” (tumor) provenian mayoritariamente de fuentes con resolucion 512×512 y modo escala de grises, mientras que las de la clase “no” (sano) presentaban resoluciones significativamente menores (mediana 228×242) y formato RGB. Estas diferencias permitian a un clasificador logistico basado unicamente en estadisticas de pixel (sin acceso al contenido visual) alcanzar un 83.5% de accuracy. Tras aplicar el pipeline de normalizacion (CenterCrop, equalizacion y conversion RGB), dicho clasificador ciego descendio a 47.5% —por debajo del azar—, confirmando la eliminacion efectiva de los artefactos. Las metricas reportadas en este estudio reflejan por tanto el desempeno real de los modelos sin atajos estadisticos.

(End of file - total 58 lines)

5. Discusion

Analisis de Sesgo Inductivo en Arquitecturas de Deep Learning: Los resultados obtenidos bajo condiciones controladas —todos los modelos entrenados desde cero con el mismo pipeline de normalizacion— revelan una jerarquia clara determinada por la presencia de sesgos inductivos convolucionales. CoAtNet (98.35%), que combina etapas convolucionales MBConv con atencion Transformer, lidera el ranking al beneficiarse de las convoluciones en las primeras capas para extraer caracteristicas locales, mientras que la atencion en capas profundas modela dependencias de largo alcance. ResNet50 (97.48%) y EfficientNet-B0 (97.00%), arquitecturas puramente convolucionales, ocupan el segundo y tercer lugar respectivamente, demostrando

que decadas de refinamiento en el diseno de CNNs producen modelos altamente eficientes incluso sin transfer learning.

En el extremo opuesto, ViT-B/16 (95.74%) obtiene el peor desempeno a pesar de tener 85.8M de parametros —3.2 veces mas que CoAtNet y 21 veces mas que EfficientNet-B0—. La atencion global, que permite a cada parche relacionarse con todos los demas, se convierte en una desventaja cuando el volumen de datos es limitado: el modelo debe aprender desde cero que pixeles cercanos estan correlacionados (localidad) y que un mismo patron puede aparecer en cualquier posicion (equivarianza traslacional), conocimientos que las CNNs incorporan estructuralmente. Swin-T (96.32%), con atencion restringida a ventanas locales de 7×7 , mitiga parcialmente esta deficiencia, superando a ViT-B/16 por 0.58 puntos porcentuales con 68% menos parametros.

Implicaciones para el Diseno de Sistemas de Diagnostico Asistido: La diferencia de 2.61 puntos porcentuales entre CoAtNet (98.35%) y ViT-B/16 (95.74%) tiene implicaciones clinicas relevantes: en un conjunto de prueba de 1033 imagenes, CoAtNet cometio aproximadamente 17 errores frente a los 44 de ViT-B/16. Para un sistema de apoyo al diagnostico, esta reduccion de errores puede traducirse en menos falsos positivos (pacientes sanos derivados innecesariamente) y menos falsos negativos (tumores no detectados).

EfficientNet-B0 merece una mencion especial: con solo 4.0M de parametros y 55.3 ms de inferencia, alcanza 97.00% de accuracy, superando a ViT-B/16 en 1.26 puntos porcentuales con el 4.7% de sus parametros. Esto lo posiciona como la opcion ideal para despliegue en entornos con recursos limitados, donde la velocidad de inferencia y el consumo de memoria son criticos.

Limitaciones del Estudio: Si bien el pipeline de normalizacion elimino los artefactos estadisticos mas evidentes (diferencia de resolucion, modo de color y distribucion de brillo entre clases), la evaluacion se limito a un unico dataset de origen publico (Kaggle). La validacion externa con imagenes de otros centros hospitalarios o protocolos de adquisicion constituye un paso necesario para confirmar la generalizabilidad de los resultados. Asimismo, el entrenamiento desde cero con 30 epocas fijas representa una configuracion basal; la incorporacion de tecnicas adicionales como data augmentation mas agresiva o aprendizaje autosupervisado podria mejorar el rendimiento, aunque a costa de introducir nuevas variables de confusion en la comparacion.

6. Conclusiones

En este trabajo se evaluaron cinco arquitecturas de deep learning (ResNet50, EfficientNet-B0, ViT-B/16, Swin-T y

CoAtNet) para la clasificación binaria de tumores cerebrales en imágenes MRI. Todos los modelos fueron entrenados desde cero con un pipeline de normalización estricta diseñado para eliminar artefactos estadísticos del dataset que inflaban artificialmente las métricas. Los principales hallazgos son:

CoAtNet, la arquitectura híbrida CNN-Transformer, obtuvo el mejor desempeño global con 98.35% de accuracy (MCC de 0.9572), demostrando que la combinación de sesgos convolucionales locales con atención global en capas profundas ofrece el equilibrio óptimo para este dominio. Las CNNs puras —ResNet50 (97.48%) y EfficientNet-B0 (97.00%)— ofrecieron un rendimiento competitivo con menor costo computacional, siendo EfficientNet-B0 particularmente eficiente con solo 4.0M de parámetros y 55.3 ms por lote. Swin-T (96.32%) superó a ViT-B/16 (95.74%) gracias a su atención local por ventanas desplazadas, confirmando que restringir el alcance de la atención a regiones anatómicamente relevantes es más efectivo que la atención global cuando los datos son limitados. ViT-B/16, pese a ser el modelo de mayor capacidad (85.8M de parámetros), obtuvo el rendimiento más bajo, evidenciando que los transformers puros requieren volúmenes de datos masivos para compensar su carencia de sesgos inductivos.

Un hallazgo metodológico relevante fue la identificación de artefactos sistemáticos en el dataset original (diferencias de resolución, modo de color y distribución de brillo entre clases) que permitían a un clasificador no profundo alcanzar 83.5% de accuracy sin acceso al contenido visual. La aplicación del pipeline de normalización (CenterCrop cuadrado, ecualización de histograma y conversión RGB forzada) redujo este baseline ciego a 47.5%, garantizando que las métricas reportadas reflejen capacidad diagnóstica genuina.

Los resultados confirman que, en regímenes de datos limitados como los típicos en aplicaciones médicas, la estructura arquitectónica (sesgos inductivos) es más determinante que la capacidad bruta de parámetros. Arquitecturas con componentes convolucionales o atención local ofrecen mejor rendimiento que los transformers puros con atención global, posicionándose como las opciones más adecuadas para el desarrollo de sistemas de diagnóstico asistido por inteligencia artificial en entornos clínicos con recursos computacionales restringidos.

7. Limitaciones

A pesar de los resultados prometedores, este estudio presenta limitaciones. El dataset utilizado, aunque representativo, proviene de una única fuente pública, lo que puede afectar la generalización a otros centros médicos con equipos y protocolos de adquisición distintos. No se realizó validación externa ni se evaluó el rendimiento de los modelos en conjuntos de datos multicéntricos. Además,

todas las arquitecturas se entrenaron desde cero sin transfer learning, lo que aumenta el tiempo de convergencia en comparación con enfoques basados en modelos preentrenados. Por último, el estudio se limitó a la clasificación de cuatro tipos de tumores; la detección temprana de tumores de grado bajo y la segmentación precisa de bordes tumorales quedan fuera del alcance de este trabajo.

8. Trabajos Futuros

Como trabajo futuro se propone validar los modelos en conjuntos de datos multicéntricos (como BraTS o TCGA) para evaluar su capacidad de generalización en entornos clínicos reales. Explorar técnicas de transfer learning con modelos preentrenados en ImageNet podría acelerar el entrenamiento y mejorar el rendimiento, especialmente en arquitecturas transformer con alta capacidad. También sería relevante integrar mecanismos de explicabilidad (e.g., Grad-CAM, atención visual) para aumentar la confianza clínica en las predicciones. Finalmente, se sugiere extender el estudio a tareas de segmentación de tumores y clasificación multiclase con grados de malignidad.

References

- [1] C. Ding, Y. Wu, X. Chen, Y. Chen, Z. Wu, Z. Lin, D. Kang, W. Fang, F. Chen, Global, regional, and national burden and attributable risk factors of neurological disorders: The global burden of disease study 1990–2019, *Frontiers in Public Health* 10 (11 2022). doi:10.3389/fpubh.2022.952161.
- [2] I. Mavroudis, D. Kazis, F. Z. Kamal, I.-L. Gurzu, A. Ciobica, M. Pădurariu, B. Novac, A. Iordache, Understanding functional neurological disorder: Recent insights and diagnostic challenges, *International Journal of Molecular Sciences* 25 (2024) 4470. doi:10.3390/ijms25084470.
- [3] S. A. Finkelstein, C. Diamond, A. Carson, J. Stone, Incidence and prevalence of functional neurological disorder: a systematic review, *Journal of Neurology, Neurosurgery & Psychiatry* 96 (2025) 383–395. doi:10.1136/jnnp-2024-334767.
- [4] M. Pichaivel, G. Anbumani, P. Theivendren, M. Gopal, An Overview of Brain Tumor, *IntechOpen*, 2022. doi:10.5772/intechopen.100806.
- [5] L. R. Schaff, I. K. Mellingshoff, Glioblastoma and other primary brain malignancies in adults, *JAMA* 329 (2023) 574. doi:10.1001/jama.2023.0023.
- [6] G. D. Barkade, P. S. Bhosale, S. K. Shirsath, Overview of brain cancer, its symptoms, diagnosis and treatment, *IP International Journal of Comprehensive and Advanced Pharmacology* 8 (2023) 159–164. doi:10.18231/j.ijcaap.2023.027.
- [7] V. Essianda, A. D. Indrasari, P. Widyastuti, T. Syahla, R. Rohadi, Brain tumor : Molecular biology, pathophysiology, and clinical symptoms, *Jurnal Biologi Tropis* 23 (2023) 260–269. doi:10.29303/jbt.v23i4.5585.
- [8] M. Martucci, R. Russo, F. Schimperna, G. D’Apolito, M. Panfili, A. Grimaldi, A. Perna, A. M. Ferranti, G. Varcasia, C. Giordano, S. Gaudino, Magnetic resonance imaging of primary adult brain tumors: State of the art and future perspectives, *Biomedicine* 11 (2023) 364. doi:10.3390/biomedicine11020364.
- [9] Y. Wang, Z. Hu, H. Wang, The clinical implications and interpretability of computational medical imaging (radiomics) in brain tumors, *Insights into Imaging* 16 (2025) 77. doi:10.1186/s13244-025-01950-6.

- [10] R. M. Nikam, X. Yue, G. Kaur, V. Kandula, A. Khair, H. H. Kecskemethy, L. W. Averill, S. A. Langhans, Advanced neuroimaging approaches to pediatric brain tumors, *Cancers* 14 (2022) 3401. [doi:10.3390/cancers14143401](#).
- [11] Y. M. A. Mohammed, S. E. Garouani, I. Jellouli, A survey of methods for brain tumor segmentation-based mri images, *Journal of Computational Design and Engineering* 10 (2023) 266–293. [doi:10.1093/jcde/qwac141](#).
- [12] A. A. A. Rabah, M. A. Binmhusien, M. H. Alotaibi, B. A. Almalki, Magnetic resonance imaging (mri): Principles, applications, and clinical utility, *Journal of Advances and Scholarly Researches in Allied Education* 21 (2024) 83–85. [doi:10.29070/qvz4sm62](#).
- [13] D. M. Taha, A. T. Abdulqader, A. M. H. Al-Khawaja, H. A. Mousa, Review article about magnetic resonance imaging (mri), *European Journal of Theoretical and Applied Sciences* 2 (2024) 530–535. [doi:10.59324/ejtas.2024.2\(5\).51](#).
- [14] S. Hussain, I. Mubeen, N. Ullah, S. S. U. D. Shah, B. A. Khan, M. Zahoor, R. Ullah, F. A. Khan, M. A. Sultan, Modern diagnostic imaging technique applications and risk factors in the medical field: A review, *BioMed Research International* 2022 (1 2022). [doi:10.1155/2022/5164970](#).
- [15] M. H. Alsaedi, F. M. H. Joman, A. F. M. Alraddadi, H. N. B. S. Alharbi, M. A. R. A. Amry, H. K. Alazhri, M. S. Almaghami, A. A. Alqubali, W. A. H. Hwsawy, F. S. Mousa, Advancements in magnetic resonance imaging: A systematic review of emerging technologies and clinical applications, *Journal of Ecohumanism* 3 (2024) 1798–1803. [doi:10.62754/joe.v3i8.4873](#).
- [16] A. B. Abdusalomov, M. Mukhiddinov, T. K. Whangbo, Brain tumor detection based on deep learning approaches and magnetic resonance imaging, *Cancers* 15 (2023) 4172. [doi:10.3390/cancers15164172](#).
- [17] T. A. Soomro, L. Zheng, A. J. Afifi, A. Ali, S. Soomro, M. Yin, J. Gao, Image segmentation for mr brain tumor detection using machine learning: A review, *IEEE Reviews in Biomedical Engineering* 16 (2023) 70–90. [doi:10.1109/RBME.2022.3185292](#).
- [18] S. Anantharajan, S. Gunasekaran, T. Subramanian, V. R. Mri brain tumor detection using deep learning and machine learning approaches, *Measurement: Sensors* 31 (2024) 101026. [doi:10.1016/j.measen.2024.101026](#).
- [19] M. S. I. Khan, A. Rahman, T. Debnath, M. R. Karim, M. K. Nasir, S. S. Band, A. Mosavi, I. Dehzangi, Accurate brain tumor detection using deep convolutional neural network, *Computational and Structural Biotechnology Journal* 20 (2022) 4733–4745. [doi:10.1016/j.csbj.2022.08.039](#).
- [20] M. I. Mahmud, M. Mamun, A. Abdelgawad, A deep analysis of brain tumor detection from mr images using deep learning networks, *Algorithms* 16 (2023) 176. [doi:10.3390/al16040176](#).
- [21] F. J. Dorfner, J. B. Patel, J. Kalpathy-Cramer, E. R. Gertner, C. P. Bridge, A review of deep learning for brain tumor analysis in mri, *npj Precision Oncology* 9 (2025) 2. [doi:10.1038/s41698-024-00789-2](#).
- [22] R. Disci, F. Gurcan, A. Soylu, Advanced brain tumor classification in mr images using transfer learning and pre-trained deep cnn models, *Cancers* 17 (2025) 121. [doi:10.3390/cancers17010121](#).
- [23] B. B. Vimala, S. Srinivasan, S. K. Mathivanan, Mahalakshmi, P. Jayagopal, G. T. Dalu, Detection and classification of brain tumor using hybrid deep learning models, *Scientific Reports* 13 (2023) 23029. [doi:10.1038/s41598-023-50505-6](#).
- [24] R. D. Prayogo, N. Hamid, H. Nambo, Hybrid cnn-based transfer learning enhances brain tumor classification on mri images, *IEEE Access* 13 (2025) 116654–116668. [doi:10.1109/ACCESS.2025.3584376](#).
- [25] C. Mitra, M. Ikbal, F. Parvin, M. M. Rahman, D. Asadujjaman, Transfer learning based multiclass brain tumor classification using mri data, in: 2025 International Conference on Quantum Photonics, Artificial Intelligence, and Networking (QPAIN), IEEE, 2025, pp. 1–6. [doi:10.1109/QPAIn66474.2025.11172074](#).
- [26] S. Panigrahi, D. R. D. Adhikary, B. K. Pattanayak, B. B. Dash, U. C. De, S. S. Patra, Interpretable multi-class brain mri tumor classification with vit-b16 transformer, in: 2025 IEEE 4th International Conference for Advancement in Technology (ICONAT), IEEE, 2025, pp. 1–5. [doi:10.1109/ICONAT66879.2025.11362544](#).
- [27] A. Jain, A. Mishra, G. Bethany, M. Gupta, A. Poulse, Advanced brain tumor classification from mri images with vision and swin transformer models, in: 2025 Emerging Technologies for Intelligent Systems (ETIS), IEEE, 2025, pp. 1–5. [doi:10.1109/ETIS64005.2025.10961204](#).
- [28] M. Aloraini, A. Khan, S. Aladhadh, S. Habib, M. F. Alsharekh, M. Islam, Combining the transformer and convolution for effective brain tumor classification using mri images, *Applied Sciences* 13 (2023) 3680. [doi:10.3390/app13063680](#).
- [29] S. Tabatabaei, K. Rezaee, M. Zhu, Attention transformer mechanism and fusion-based deep learning architecture for mri brain tumor classification system, *Biomedical Signal Processing and Control* 86 (2023) 105119. [doi:10.1016/j.bspc.2023.105119](#).
- [30] C. Lv, X.-J. Shu, Q. Liang, J. Qiu, Z.-C. Xiong, J. bo Ye, S. bo Li, C. Q. Liu, J. Z. Niu, S.-B. Chen, H. Rao, Brain-tumnet: multi-task deep learning framework for brain tumor segmentation and classification using adaptive masked transformers, *Frontiers in Oncology* 15 (5 2025). [doi:10.3389/fonc.2025.1585891](#).
- [31] K. Dang, T. Vo, L. Ngo, H. Ha, A deep learning framework integrating mri image preprocessing methods for brain tumor segmentation and classification, *IBRO Neuroscience Reports* 13 (2022) 523–532. [doi:10.1016/j.ibneur.2022.10.014](#).
- [32] N. Kühl, M. Schemmer, M. Goutier, G. Satzger, Artificial intelligence and machine learning, *Electronic Markets* 32 (4) (2022) 2235–2244. [doi:10.1007/s12525-022-00598-0](#).
- [33] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie, L. Farhan, Review of deep learning: Concepts, cnn architectures, challenges, applications, future directions, *Journal of Big Data* 8 (2021) 53. [doi:10.1186/s40537-021-00444-8](#).
- [34] M. Li, Y. Jiang, Y. Zhang, H. Zhu, Medical image analysis using deep learning algorithms, *Frontiers in Public Health* 11 (2023) 1273253. [doi:10.3389/fpubh.2023.1273253](#).
- [35] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, M. Parmar, A review of convolutional neural networks in computer vision, *Artificial Intelligence Review* 57 (2024). [doi:10.1007/s10462-024-10721-6](#).
- [36] Y. Wang, Y. Deng, Y. Zheng, P. Chattopadhyay, L. Wang, Vision transformers for image classification: A comparative survey, *Technologies* 13 (1) (2025) 32. [doi:10.3390/technologies13010032](#).
- [37] A. Khan, Z. Rauf, A. Sohail, A. R. Khan, H. Asif, A. Asif, U. Farooq, A survey of the vision transformers and their cnn-transformer based variants, *Artificial Intelligence Review* 56 (2023) 2917–2970. [doi:10.1007/s10462-023-10595-0](#).
- [38] A. Salehi, S. Khan, G. Gupta, B. Alabdullah, A. Almjally, H. Alsolai, T. Siddiqui, A. Mellit, A study of cnn and transfer learning in medical imaging: Advantages, challenges, future scope, *Sustainability* 15 (7) (2023) 5930. [doi:10.3390/su15075930](#).
- [39] O. Rainio, J. Teuho, R. Klén, Evaluation metrics and statistical tests for machine learning, *Scientific Reports* 14 (2024). [doi:10.1038/s41598-024-56706-x](#).
- [40] K. Gao, S. Tasneem, T. M. Khoshgoftaar, Medical imaging with deep learning: A comparison of cnn and transformer models, in: 2025 International Conference on Machine Learning and Applications (ICMLA), 2025, pp. 523–530. [doi:10.1109/ICMLA66185.2025.00077](#).
- [41] M. Rana, M. Bhushan, Machine learning and deep learning approach for medical image analysis: diagnosis to detection, *Multimedia Tools and Applications* 82 (2022) 26731–26769. [doi:10.1007/s11042-022-14305-w](#).
- [42] M. Puttagunta, S. Ravi, Medical image analysis based on deep learning approach, *Multimedia Tools and Applications* 80 (2021) 24365–24398. [doi:10.1007/s11042-021-10707-4](#).
- [43] M. Beirović, A. Kurtović, N. Smajlović, M. Kapo, A. Akagić,

- Performance comparison of medical image classification systems using tensorflow keras, pytorch, and jax, arXiv (2025). doi: 10.48550/arXiv.2507.14587.
URL <https://arxiv.org/abs/2507.14587>
- [44] H. Laçi, K. Sevrani, S. Iqbal, Deep learning approaches for classification tasks in medical x-ray, mri, and ultrasound images: a scoping review, BMC Medical Imaging 25 (2025) 209. doi:10.1186/s12880-025-01701-5.
- [45] Shashin, Brain tumor mri datasets, Kaggle (2024).
URL <https://www.kaggle.com/datasets/luluw8071/brain-tumor-mri-datasets>