

Evaluación Comparativa de Arquitecturas de Deep Learning para Clasificación de Tumores Cerebrales en MRI

Sergio Danilo Hanco Mullisaca^{a,*}, Eduardo Joel Cuno Salazar^{a,*}, Mathias Alonso Barrios Medina^{a,*}, Miguel Angel Alvarez Choque^{a,*}

^aUniversidad Nacional de San Agustín, Arequipa, Perú.

Abstract

En el presente trabajo se lleva a cabo una evaluación comparativa de cinco arquitecturas de aprendizaje profundo —ResNet-50, EfficientNet-B0, ViT-B/16, Swin Transformer y CoAtNet— orientada a la clasificación binaria de tumores cerebrales mediante imágenes de resonancia magnética. Se empleó un dataset público integrado por 8764 imágenes, aplicando una estrategia rigurosa de partición anterior a toda expansión sintética de datos para evitar contaminación cruzada. Cada arquitectura fue evaluada en dos etapas: una etapa base (30 épocas, tasa de aprendizaje constante) y una etapa refinada (early stopping, ReduceLROnPlateau, data augmentation). EfficientNet-B0 logró 99.60 % de accuracy y 0.9998 de AUC-ROC utilizando solo 4.0 M de parámetros, mientras que Swin-T alcanzó el AUC-ROC más elevado (0.9999). ViT-B/16, a pesar de contar con la mayor capacidad de parámetros (85.8 M), exhibió el rendimiento más bajo derivado del sobreajuste. Los resultados evidencian que las arquitecturas dotadas de sesgos convolucionales o mecanismos de atención local resultan más apropiadas para conjuntos de datos médicos de magnitud moderada.

Keywords: clasificación de tumores cerebrales, deep learning, EfficientNet, Swin Transformer, resonancia magnética

1. Introducción

Las alteraciones neurológicas abarcan un conjunto heterogéneo de trastornos que impactan tanto el sistema nervioso central como el periférico, comprometiendo funciones críticas como la motricidad, memoria, cognición y percepción. Estas patologías constituyen una de las causas predominantes de discapacidad e incapacidad a nivel mundial [1]. Durante las últimas décadas, su prevalencia ha experimentado un incremento significativo asociado al envejecimiento poblacional y a múltiples factores de riesgo concurrentes, generando una demanda creciente de instrumentos diagnósticos y terapéuticos mejorados [1]. La heterogeneidad clínica de estas afecciones —que incluye procesos neurodegenerativos, cerebrovasculares y funcionales— complica considerablemente el diagnóstico debido a la complejidad y sobreposición de sus presentaciones clínicas [2] [3].

Entre las patologías oncológicas del sistema nervioso central, los tumores cerebrales representan un grupo diverso

de neoplasias con origen primario encefálico o secundario por metastatización, exhibiendo grados de malignidad e historias naturales muy variables [4]. El glioblastoma destaca como la neoplasia maligna primaria intracraneal más prevalente en la población adulta, caracterizándose por su conducta infiltrativa, alta tendencia a recidivar y pronóstico desfavorable aun con tratamientos contemporáneos [5]. La sintomatología clínica presenta variabilidad en función de la localización topográfica, magnitud y velocidad de expansión tumoral, frecuentemente manifestándose mediante cefaleas refractarias, crisis convulsivas, disfunción cognitiva y déficits neurológicos focales que deterioran progresivamente la calidad de vida [6] [7]. La complejidad inherente a la biología molecular y fisiopatología de estas lesiones constituye un obstáculo significativo para el diagnóstico preciso y la selección óptima de estrategias terapéuticas [7].

La resonancia magnética (MRI) permanece como la modalidad de neuroimagen de elección para la detección y caracterización de masas intracraneales, gracias a su excelente resolución de contraste en estructuras de partes blandas y su capacidad para determinar con precisión la localización espacial, extensión y características morfológicas de lesiones [8]. En paralelo, el desarrollo de metodologías radiómicas permite extraer atributos cuantitativos de las imágenes para mejorar la clasificación de neoplasias, estimación pronóstica y orientación clínica mediante la integración de técnicas de inteligencia artificial [9]. Las aproximaciones modernas en neuroimagen incorporan in-

*Corresponding author.

Email addresses: shanccom@unsa.edu.pe (Sergio Danilo Hanco Mullisaca), ecunos@unsa.edu.pe (Eduardo Joel Cuno Salazar), mbarriosmed@unsa.edu.pe (Mathias Alonso Barrios Medina), malvarezcho@unsa.edu.pe (Miguel Angel Alvarez Choque)

URL: <https://orcid.org/0009-0002-6080-8661> (Sergio Danilo Hanco Mullisaca), <https://orcid.org/0009-0005-9736-404X> (Eduardo Joel Cuno Salazar), <https://orcid.org/0009-0003-6772-3035> (Mathias Alonso Barrios Medina), <https://orcid.org/0009-0003-9502-4493> (Miguel Angel Alvarez Choque)

formación anatómica, dinámica y metabólica de forma integrada, facilitando una comprensión más completa de la naturaleza tumoral y optimizando la planificación de intervenciones terapéuticas [10]. En esta perspectiva, la segmentación automática de imágenes de resonancia magnética se ha consolidado como un componente fundamental para delimitar territorios tumorales y sustentar sistemas de asistencia diagnóstica basados en aprendizaje automático y redes neuronales profundas [11].

La tecnología de resonancia magnética por imágenes (MRI) constituye un método diagnóstico no invasivo que aprovecha campos magnéticos intensos y radiaciones de radiofrecuencia para producir representaciones de alta definición de órganos y tejidos, sin exposición a radiación ionizante [12][13]. La superior resolución espacial combinada con el contraste diferencial entre tejidos blandos la posiciona como una herramienta indispensable en la evaluación de padecimientos neurológicos, particularmente en la visualización y caracterización de masas encefálicas [12][14]. Los avances recientes en protocolos de adquisición y algoritmos de procesamiento han mejorado substancialmente la calidad diagnóstica y ampliado el espectro de aplicaciones clínicas [15]. Por estas razones, la MRI constituye la base fundamental de numerosos sistemas computacionales de inteligencia artificial, suministrando imágenes de elevada resolución que facilitan la detección y clasificación automatizada de irregularidades del sistema nervioso central [15][14][13].

Un aspecto limitante del enfoque tradicional radica en que la inspección visual de imágenes resulta sumamente laboriosa y vulnerable a la fatiga atencional de profesionales en radiología [16]. Además, la identificación manual es propensa a imprecisiones derivadas de la variabilidad en la interpretación humana. La necesidad de analizar decenas de cortes transversales para emitir un juicio diagnóstico confiable genera un volumen de trabajo que puede retrasar el inicio de intervenciones médicas urgentes.

La identificación de masas encefálicas presenta complejidad inherente a su variabilidad morfológica. Las neoplasias cerebrales típicamente exhiben configuraciones asimétricas, límites difusos e intensidades de señal similares al tejido nervioso sano. La presencia concomitante de artefactos de imagen o degradación de la calidad por error técnico dificulta adicionalmente la visibilidad de hallazgos patológicos [17]. Las metodologías convencionales de análisis frecuentemente fallan ante estas variaciones en iluminación y contraste. Estas limitaciones fundamentan la necesidad clínica de implementar sistemas de procesamiento automatizado con elevada precisión diagnóstica.

La inteligencia artificial emerge como una alternativa promisoría ante estos desafíos clínicos. Los sistemas computacionales poseen la capacidad de procesar volúmenes masivos de imágenes en tiempos muy breves. Estas herramientas funcionan como soporte de segunda opinión para especialistas en radiología en contextos hospitalarios. El

empleo de algoritmos sofisticados minimiza significativamente la inconsistencia inter e intraobservador en valoraciones diagnósticas. Esta tecnología está revolucionando los enfoques actuales para patologías oncológicas [18].

El aprendizaje profundo ha demostrado superioridad en tareas de reconocimiento visual médico. Las Redes Neuronales Convolucionales (CNN) representan el paradigma establecido para estas labores perceptivas complejas. Estos modelos matemáticos extraen de forma completamente automatizada los descriptores anatómicos presentes en imágenes de resonancia, sin necesidad de ingeniería manual de atributos [19]. Las CNN eliminan la dependencia de identificar manualmente áreas de interés clínico en las imágenes. Su potencial analítico potencia la detección de anomalías estructurales encefálicas.

Numerosas investigaciones sustentan la alta performance de estas arquitecturas en escenarios clínicos experimentales [20]. Los modelos contemporáneos logran diferenciar de manera efectiva entre diversas categorías de tumores cerebrales. La aplicación de estas metodologías acelera significativamente los tiempos de respuesta en procesos decisivos clínicos [21]. No obstante, la evaluación sistemática y comparativa de diferentes arquitecturas bajo condiciones equivalentes permanece como una necesidad de investigación. Es fundamental contrastar el desempeño de estos algoritmos empleando bases de datos públicas y recientes.

El objetivo central de esta investigación es realizar una comparación estructurada de múltiples modelos de aprendizaje profundo para la identificación de tumores en estudios de resonancia magnética cerebral. El estudio analiza el rendimiento de distintas arquitecturas neuronales convolucionales utilizando un dataset obtenido de la plataforma Kaggle. La presentación del artículo sigue una estructura progresiva. En la sección siguiente se exponen los trabajos previos identificados mediante herramientas de inteligencia artificial. Las secciones posteriores detallan de forma sistemática los materiales y procedimientos experimentales, los hallazgos de cada arquitectura, el análisis integrado, la discusión interpretativa y las conclusiones derivadas.

2. Trabajos Relacionados

La inconsistencia y carencia de normalización en conjuntos de imágenes de resonancia magnética obstaculizan tanto el diagnóstico automatizado como la precisión en la detección de patologías neurológicas. En una investigación previa, se propuso valorar el desempeño comparativo de diversas arquitecturas preentrenadas mediante la estrategia de aprendizaje por transferencia para categorizar cuatro tipos distintos de masas cerebrales. El aporte fundamental consistió en analizar de forma sistemática arquitecturas profundas tales como Xception, ResNet50, VGG16 y DenseNet121. La aproximación metodológica utilizó un conjunto de datos público disponible en Kaggle que contenía

7023 imágenes MRI dedicadas al entrenamiento y optimización de los parámetros de la red. El modelo Xception logró una precisión del 98.73 % como resultado principal. Sin embargo, se identificó una limitación importante: menor sensibilidad para las categorías glioma y meningioma, [22].

La degradación de resolución espacial y la presencia de artefactos técnicos en resonancias magnéticas reducen la eficiencia en la detección precoz de neoplasias. Un estudio previo se orientó a mejorar los procesos de categorización mediante el refinamiento secuencial específico de la familia de redes EfficientNet. La contribución radió en la explotación sistemática de los parámetros de escalamiento de EfficientNetB0-B4 orientada a capturar descriptores sutiles de los tejidos. La metodología incorporó el procesamiento de un dataset público proveniente de Figshare junto con un flujo de trabajo de entrenamiento que incluía optimizadores avanzados para prevenir sobreajuste. Se consiguió un 99.06 % de accuracy, 98.73 % en precisión, 99.13 % en sensibilidad y un F1-score de 98.79 %. Como deficiencia notable, se carece de un protocolo de validación externa bajo condiciones clínicas auténticas [23].

El consumo computacional elevado y la pérdida de información de escala global disminuyen la capacidad de las redes neuronales independientes en problemas de categorización multiclase de tumores. Una investigación desarrolló un sistema híbrido de clasificación que sintetiza los beneficios de múltiples extractores automáticos de características. El aporte radicó en el diseño de un modelo ensamblado que integra componentes de ResNet50V2, MobileNetV2 y DenseNet121. El procedimiento metodológico fusionó los vectores característicos derivados de 7023 imágenes de un repositorio público antes del módulo de clasificación terminal. El modelo resultante logró un 98.75 % de accuracy, con métricas de precisión del 98.76 % y F1-score del 98.75 %. Como debilidad identificada, se utilizaron exclusivamente datos públicos preprocesados, sin considerar el impacto que el ruido inherente al ambiente clínico y los valores atípicos ejercen sobre sistemas complejos [24].

Las variaciones morfológicas complejas presentes en imágenes de resonancia magnética limitan la discriminación de redes convolucionales tradicionales para diferenciar entre múltiples estadios de masas tumorales. Una investigación previa optimizó la categorización multiclase mediante el ajuste fino secuencial de ResNet50 enriquecida con capas totalmente conectadas suplementarias. El aporte esencial consistió en el diseño de un módulo de clasificación personalizado que maximiza la preservación de atributos jerárquicos preentrenados. El procedimiento requirió la consolidación y procesamiento de tres bases de datos públicas distintas: SARTAJ, Br35H y Figshare. Como resultado, la arquitectura modificada alcanzó una exactitud sobresaliente del 99.31 %, con mejoras paralelas en F1-score, precisión, sensibilidad y el área bajo la curva (AUC). La brecha metodológica identificada radica en que no se reali-

zó contraste del rendimiento mediante validación externa clínica [25].

La limitación intrínseca de las operaciones convolutivas de alcance local para modelar relaciones espaciales de largo rango afecta la precisión en la delineación de bordes tumorales difusos. Una investigación exploró la viabilidad de mecanismos de auto-atención global mediante la aplicación del modelo preentrenado Vision Transformer ViT-B/16. La contribución principal residió en la explotación del procesamiento parcelado de imágenes (patch embedding) para capturar vínculos contextuales sofisticados en cortes encefálicos. El procedimiento llevó a cabo un refinamiento integral sobre un conjunto de datos público de resonancia magnética estructurado en cuatro categorías patológicas. El experimento reportó una exactitud máxima del 99.24 % en el conjunto de validación para ViT-B/16. La brecha metodológica identificada consiste en que el estudio no especifica el empleo de una cohorte externa de validación [26].

El costo operacional significativo y la demanda masiva de datos que caracterizan a los Transformers convencionales limitan su viabilidad práctica en entornos de diagnóstico médico automatizado. Una investigación llevó a cabo una comparación directa entre las capacidades de procesamiento del Vision Transformer estándar y la arquitectura Swin Transformer con ventanas desplazables. La aportación central se enfocó en demostrar la eficiencia del Swin Transformer en el procesamiento de información a múltiples resoluciones espaciales con complejidad computacional lineal. El procedimiento implementó el entrenamiento estratificado de ambas aproximaciones utilizando un repositorio público indexado en Kaggle que contenía un total de 3000 imágenes MRI. Los resultados estadísticos corroboraron la superioridad del modelo Swin al alcanzar un 98.71 % de exactitud frente al 95.30 % logrado por la arquitectura ViT. Como limitación, el estudio se restringió a un dataset de escala moderada [27].

La pérdida de información de alta frecuencia causada por el escalamiento global de los Transformers afecta la precisión en la delimitación de anomalías de pequeña magnitud milimétrica. Un trabajo previo integró las capacidades locales de las redes convolucionales con el modelado de dependencias globales característico de módulos Transformer dentro de una estructura unificada. El aporte consistió en el desarrollo del modelo híbrido TECNN, que funciona como equivalente a una arquitectura CvT (Convolutional Vision Transformer). El procedimiento validó de forma rigurosa el pipeline computacional usando dos plataformas públicas de manera independiente: BraTS 2018 y Figshare. El sistema logró un 96.75 % de exactitud en el dataset desafiante de BraTS 2018 y un 99.10 % en Figshare. Su limitación radica en que el marco no emplea la arquitectura CvT nominal de referencia, sino una aproximación híbrida propia [28].

La degradación de gradientes en redes profundas obstacu-

liza la extracción simultánea de patrones locales de textura y conceptos contextuales abstractos. Un estudio diseñó un marco de aprendizaje simétrico de dos ramas paralelas que integra módulos Transformer con redes residuales optimizadas. La aportación se basó en el acoplamiento de un módulo de auto-atención (Self-Attention) junto a una arquitectura iResNet adaptada para estabilizar la propagación de información. El procedimiento requirió el análisis de 3064 secciones de resonancias magnéticas del repositorio Figshare, distribuidas en cuatro categorías diagnósticas. Los ensayos de validación demostraron que el extractor basado en iResNet alcanzó un 99.30 % de exactitud, mejorando la capacidad de generalización en un 20 % de muestras no observadas durante el ajuste. La debilidad identificada consiste en la carencia de validación frente a una cohorte clínica externa auténtica [29].

La separación metodológica entre sistemas de segmentación y clasificación obliga a las instituciones médicas a desplegar pipelines computacionales redundantes y onerosos. Una investigación unificó ambas labores dentro de un único marco de aprendizaje optimizado para datos médicos. La aportación principal radicó en el diseño de un Adaptive Masked Transformer capaz de resolver tareas múltiples de forma simultánea. El procedimiento empleó 485 casos clínicos privados junto con un conjunto de datos independiente para la validación externa del sistema. El modelo alcanzó un Dice de 0.91 y una exactitud de clasificación del 93.4 %. La limitación del enfoque consiste en que la precisión final de la categorización quedó considerablemente por debajo de los modelos especializados dedicados a etiquetado [30].

La prevalencia de ruido de alta frecuencia y la variabilidad de contraste entre escáneres de distintos fabricantes deterioran el rendimiento de las redes U-Net convencionales. Una investigación estructuró un flujo de trabajo progresivo que integrara filtrado de ruido, segmentación y posterior categorización jerárquica de gliomas. El aporte residuó en un proceso de trabajo integrado que conecta una red U-Net con clasificadores derivados de VGG y GoogLeNet. El procedimiento validó el pipeline sobre el conjunto BraTS2019, ejecutando tareas de segmentación y categorización en etapas secuenciales. Los resultados alcanzaron un Dice de 0.82/0.91/0.72 en las subtarefas de segmentación y un 97.44 % de exactitud en la categorización. La limitación radica en que el modelo requiere mejoras arquitectónicas fundamentales por carencia de originalidad en los bloques de integración [31].

Al revisar la literatura científica contemporánea, se identifican dos brechas metodológicas de relevancia fundamental. Primero, la mayor parte de las investigaciones previas orientadas a datasets públicos de Kaggle o Figshare [22, 23, 24, 25, 26, 27] incurrir en el error técnico de aplicar algoritmos de expansión sintética de datos de forma global sobre la totalidad del conjunto de imágenes previo a la partición. Esta práctica causa un fenómeno grave de fuga de datos (Data Leakage), donde variantes modifica-

das de una imagen original terminan distribuidas simultáneamente en los conjuntos de entrenamiento, validación y prueba, inflando artificialmente las métricas de desempeño y reduciendo la capacidad genuina de generalización.

Segundo, la generalidad de los trabajos previos abordan el problema como categorización multiclase (glioma, meningioma, pituitario, sin tumor). Aunque esta granularidad diagnóstica posee valor, introduce una complejidad añadida que dificulta la evaluación controlada de pipelines de preprocesamiento y particionamiento. Por este motivo, el presente trabajo adopta un enfoque de categorización binaria (sí/no tumor), para lo cual se seleccionó un subconjunto aleatorio del 20 % de los datos originales y se reestructuró explícitamente en dos categorías: sí (con tumor, integrando gliomas, meningiomas y demás variantes) y no (cerebro sano, sin tumor). Esta simplificación permite aislar y valorar con mayor rigor el impacto de las decisiones metodológicas sobre el preprocesamiento de datos, minimizando las variables confusoras asociadas a la granularidad multiclase.

Asimismo, se evidencia una carencia de protocolos sistematizados para la detección y corrección de anomalías visuales u outliers previos al entrenamiento. El presente trabajo aborda de manera directa estas carencias implementando un pipeline de automatización rigurosa (Data Automation Split) donde la partición en tres grupos independientes (Train, Validation y Test) se ejecuta de forma prioritaria y absoluta antes de cualquier técnica de expansión sintética de datos. De igual forma, se integra el uso de algoritmos avanzados de detección de anomalías (Outliers) para garantizar la pureza del conjunto de datos y asegurar la robustez clínica del modelo propuesto.

A continuación, se presenta la Tabla 1, la cual sintetiza los aportes, resultados y deficiencias metodológicas de las investigaciones analizadas en esta sección.

Cuadro 1: Tabla comparativa de la literatura científica analizada para la detección y segmentación de tumores cerebrales.

Autor y Año	Modelo / Aporte Principal	Resultados Clave	Deficiencia o Brecha Identificada
[22]	Transfer Learning (Xception, ResNet50, VGG16)	Accuracy: 98.73 %, F1: 95.29 %	Menor recall en glioma; explicabilidad y diversidad de datos limitadas.
[23]	EfficientNetB0-B4 fine-tuned en CE-MRI	Accuracy: 99.06 %, F1: 98.79 %	Ausencia total de validación externa en entornos clínicos reales.
[24]	Ensamble híbrido (ResNet50 V2 + MobileNet V2 + DenseNet121)	Accuracy: 98.75 %, F1: 98.75 %	Dependencia de datasets públicos compuestos; sensible a ruido y outliers.
[25]	Fine-tuning de ResNet50 + Capas adicionales	Accuracy: 99.31 %, Alto AUC	No reporta validación externa con muestras de origen clínico real.
[26]	Vision Transformer (ViT-B/16) fine-tuned	Accuracy: 99.24 %	Falta de descripción de cohortes externas y validación multicéntrica.
[27]	Comparación ViT vs. Swin Transformer	Swin Acc: 98.71 %, ViT Acc: 95.30 %	Dataset de escala moderada y ausencia de esquemas de validación externa.
[28]	TECNN híbrido (Convolución + Transformer)	Acc BraTS: 96.75 %, Figshare: 99.10 %	No emplea CvT nominal; es un desarrollo híbrido propio ad-hoc.
[29]	Dos ramas (iResNet + Self-Attention Module)	Accuracy: 99.30 %, Gen. +20 %	Evaluado solo en bases públicas; sin reporte de cohorte clínica externa.
[30]	Multitarea con Adaptive Masked Transformer	IoU: 0.921, Clasificación Acc: 93.4 %	La precisión de clasificación queda por debajo de los modelos monoproósito.
[31]	Pipeline integrado UNet + VGG/GoogLeNet	Segmentación Dice: 0.82; Clasificación Acc: 97.44 %	Falta de originalidad en la arquitectura base; requiere optimización estructural.

3. Materiales y Metodos

3.1. Fundamentos teóricos

La Inteligencia Artificial (IA) constituye un área de la informática dedicada a la construcción de sistemas capaces de percibir entornos específicos, procesarlos mediante razonamiento abstracto y ejecutar acciones determinadas para lograr metas específicas de forma inteligente [32]. El aprendizaje automático (ML) representa una subdisciplina de la IA que habilita a los sistemas computacionales para adquirir conocimiento a partir de datos y mejorar su capacidad de desempeño sin necesidad de programación explícita para cada tarea individual [32]. Aunque estos términos frecuentemente se utilizan de forma equivalente, la IA engloba diversos enfoques para construir sistemas dotados de inteligencia, mientras que el aprendizaje automático se concentra específicamente en la adquisición de conocimiento mediante experiencia y datos [32]. Esta relación posiciona al aprendizaje automático como uno de los métodos fundamentales en la construcción de aplicaciones contemporáneas de inteligencia artificial [32].

El aprendizaje profundo o deep learning constituye una rama especializada del aprendizaje automático que utiliza arquitecturas de redes neuronales multicapa para aprender representaciones jerárquicas y complejas de los datos [33]. A diferencia de metodologías convencionales, esta aproximación extrae de forma completamente autónoma los atributos

más significativos sin requerir ingeniería manual de características [33]. Debido a esta capacidad distintiva, el aprendizaje profundo encuentra aplicación en tareas tan variadas como reconocimiento visual de imágenes, síntesis de voz, procesamiento de lenguaje natural y análisis computacional de escenas visuales [33]. Su rendimiento sobresaliente y aptitud para procesar volúmenes masivos de información han posicionado al aprendizaje profundo como una de las tecnologías más influyentes en la inteligencia artificial contemporánea [33].

El reconocimiento y categorización de imágenes en contexto médico comprende la identificación de estructuras anatómicas, tipos de tejido o patologías presentes en representaciones visuales obtenidas mediante modalidades diagnósticas tales como resonancia magnética, tomografía computarizada y radiografía convencional [34]. Para ello, los algoritmos de aprendizaje profundo analizan de forma automática las imágenes y extraen atributos significativos que permiten asignar una categoría diagnóstica apropiada [34]. Este proceso facilita la visualización de enfermedades, la discriminación entre tejidos fisiológicos y afecciones patológicas, y el apoyo a procesos decisivos en contextos clínicos [34]. Gracias a su exactitud y potencia para procesar volúmenes considerables de información visual, esta metodología constituye una herramienta esencial en la medicina con asistencia de inteligencia artificial [34].

Las Redes Neuronales Convolucionales (CNN) son arquitecturas de aprendizaje profundo elaboradas específicamente para procesar información dotada de estructura espacial, particularmente imágenes [35]. Estas redes extraen de forma autónoma descriptores mediante operaciones de convolución, reducción de dimensionalidad (pooling) y transformaciones no lineales de activación, aprendiendo patrones que van desde representaciones simples hasta conceptos altamente abstractos [35]. Debido a este mecanismo operacional, las CNN se emplean ampliamente en problemas de categorización, localización y delineación de imágenes [35]. Su capacidad inherente para adquirir atributos visuales de manera automática las ha constituido como una de las arquitecturas más prominentes en campos como la visión computacional e imágenes médicas [35].

Los Vision Transformers (ViT) constituyen arquitecturas de aprendizaje profundo que transportan el mecanismo de auto-atención (self-attention) característico de Transformers al dominio del análisis de imágenes [36]. Estos modelos segmentan una imagen en parches de tamaño uniforme que son procesados como secuencias para capturar tanto relaciones de proximidad como patrones globales [36]. Derivado de este enfoque, los Vision Transformers se utilizan en categorización, localización y segmentación de imágenes [36]. Su competencia en el modelado de dependencias de alcance extenso los ha posicionado como una alternativa equivalente a las redes neuronales convolucionales en aplicaciones de visión computacional [36].

Los modelos híbridos CNN-Transformer son arquitecturas que sintetizan las capacidades de redes neuronales convolucionales y Vision Transformers en el análisis de escenas visuales [37]. Estos modelos aprovechan las CNN para la extracción de características de alcance reducido y los Transformers para la captura de relaciones de alcance global mediante mecanismos de auto-atención [37]. Como resultado, producen representaciones más comprehensivas que mejoran substancialmente el desempeño en categorización, localización y delineación de imágenes [37]. Gracias a este equilibrio entre exactitud y capacidad representativa, los modelos híbridos configuran una alternativa de considerable potencial para aplicaciones de visión computacional e imágenes médicas [37].

El aprendizaje por transferencia (Transfer Learning) constituye una metodología que reutiliza modelos previamente entrenados para resolver tareas novedosas empleando volúmenes de datos limitados [38]. Este enfoque aprovecha el conocimiento acumulado por redes profundas para abreviar tiempos de entrenamiento y potenciar el rendimiento en nuevas aplicaciones [38]. Adicionalmente, frecuentemente se combina con estrategias tales como expansión sintética de datos (data augmentation) y optimización paramétrica (fine-tuning) para incrementar la aptitud del modelo para generalizar a datos no observados [38]. Gracias a estas ventajas operativas, el aprendizaje por transferencia goza de amplia utilización en sistemas de análisis y categoriza-

ción de imágenes médicas basados en inteligencia artificial [38].

Las métricas de evaluación constituyen medidas numéricas empleadas para cuantificar el desempeño y la aptitud de generalización de un modelo de aprendizaje automático [39]. La selección de una métrica particular depende de la naturaleza del problema de categorización y de los objetivos específicos de la aplicación [39]. Entre las medidas más frecuentemente utilizadas figuran la exactitud (accuracy), la precisión (precision), la sensibilidad (recall), la puntuación F1 y el área bajo la curva ROC (AUC), siendo cada una de ellas indicativa de un aspecto distintivo del rendimiento del modelo [39]. El análisis conjunto de estas métricas permite una valoración más íntegra y confiable del comportamiento de un sistema de aprendizaje automático [39].

La comparación de arquitecturas de aprendizaje profundo para categorización de imágenes médicas consiste en el análisis sistemático del desempeño de distintos modelos con el propósito de identificar cuál se adecua de forma óptima a una tarea determinada [40]. Este proceso valora aspectos tales como la exactitud, la eficiencia computacional y la aptitud de generalización de arquitecturas fundadas en Redes Neuronales Convolucionales y Vision Transformers [40]. La comparación sistemática permite identificar las ventajas inherentes y limitaciones de cada modelo en función de las particularidades del conjunto de datos y de la naturaleza del problema de categorización [40]. Estos análisis constituyen una etapa cardinal en la selección de la arquitectura más apropiada en el desarrollo de sistemas de asistencia diagnóstica automatizada mediante inteligencia artificial [40].

3.2. Herramientas y Tecnologías

Se utilizará Python 3.11 como lenguaje de programación base del desarrollo, selección justificada por la disponibilidad de un ecosistema extenso de bibliotecas orientadas al aprendizaje automático y aprendizaje profundo. Conforme a Rana y Bhushan [41], Python se ha posicionado como el lenguaje predominante en aplicaciones de inteligencia artificial centradas en análisis de imágenes médicas. Además, se empleará Google Colab como entorno computacional en línea, proporcionando acceso a aceleradores GPU y facilitando la replicabilidad de experimentos sin requerir infraestructura local de elevado desempeño. Según Puttagunta y Ravi [42], la configuración adecuada del ambiente de hardware y software es fundamental para asegurar la reproducibilidad de investigaciones computacionales.

Se empleará TensorFlow 2.18.0 y Keras 3.8.0 para la implementación de arquitecturas basadas en convoluciones tales como ResNet50 y EfficientNet-B0, en tanto que los modelos fundamentados en Transformers (ViT-B/16, Swin Transformer y CoAtNet) serán programados utilizando PyTorch 2.6 y timm 1.0. Beirović et al. [43] presentan un

análisis comparativo de estos frameworks para categorización de imágenes médicas. El acondicionamiento previo de las imágenes se realizará con OpenCV 4.10, NumPy 2.2 para cálculos matriciales, scikit-learn 1.6 para métricas de desempeño y particionamiento de datos, y Matplotlib 3.10 para visualización de resultados. Laçi et al. [44] señalan que TensorFlow, Keras y PyTorch constituyen los frameworks más ampliamente adoptados en aprendizaje profundo aplicado a imágenes médicas.

3.3. Dataset

Este proyecto empleará el dataset denominado *Brain Tumor MRI Datasets*, disponible públicamente en la plataforma Kaggle y publicado por Shashin [45]. Este conjunto de datos comprende 8764 imágenes de resonancia magnética cerebral estructuradas para una tarea de categorización binaria.

Las imágenes se encuentran organizadas en dos categorías: Yes (sujetos que presentan tumor cerebral) y No (sujetos sin hallazgos tumorales).




Figura 1: Ejemplar de imagen de la categoría “Yes”.




Figura 2: Ejemplar de imagen de la categoría “No”.

El conjunto se encuentra particionado en un 80 % destinado a entrenamiento y un 20 % reservado para validación, estrategia que facilita el desarrollo y la valoración de modelos de aprendizaje profundo. Considerando que se trata de un dataset de imágenes, carece de atributos tabulares convencionales; cada registro se compone de una imagen de resonancia magnética acompañada de su correspondiente etiqueta categórica.

Cuadro 2: Descripción de las variables del dataset.

Variable	Descripción
Imagen MRI	Imagen de resonancia magnética cerebral.
Clase	Etiqueta de la imagen (“Yes” o “No”).
Train/Test	Indica si la imagen pertenece al conjunto de entrenamiento o de prueba.

La estructura del conjunto de datos se organiza en dos subgrupos distintos: entrenamiento y prueba. La caracterización del volumen de imágenes según categoría se presenta en la Tabla 3.

Cuadro 3: Distribución de imágenes por clase y conjunto.

Conjunto	No Tumor	Tumor	Total
Train	2869	4143	7012
Test	717	1035	1752
Total	3586	5178	8764

Con propósito de caracterizar la composición del conjunto, se efectuó un análisis considerando la cantidad de ejemplares por categoría y por partición.




Figura 3: Distribución total de imágenes por clase.

Según se observa en la Figura 3, el conjunto contiene 5178 imágenes con tumor (59.1 %) y 3586 imágenes sin tumor (40.9 %). Esto indica un ligero desequilibrio entre categorías, aunque la magnitud de la diferencia no resulta lo suficientemente pronunciada para comprometer significativamente el entrenamiento.




Figura 4: Distribución de imágenes por conjunto de entrenamiento y prueba.

La Figura 4 ilustra que la proporción de imágenes se mantiene consistente tanto en el subgrupo de entrenamiento como en el de prueba. En ambas particiones, la categoría Tumor exhibe una cantidad superior de muestras comparada con la categoría No Tumor, preservando una relación proporcional equiparable entre ambos subconjuntos.




Figura 5: Distribución porcentual de las clases del dataset.

La Figura 5 presenta la distribución porcentual de los ejemplares del dataset. Se aprecia que el 59.1 % corresponde a imágenes que presentan tumor cerebral, en tanto que el 40.9 % pertenece a imágenes sin tumor. Este diferencial revela un desequilibrio moderado entre categorías que requiere consideración durante las fases de entrenamiento.

3.4. Metodología propuesta

Previo a la carga en estructuras tensoriales, los ficheros de imagen del repositorio se someterán a una verificación exhaustiva de formato e integridad mediante la biblioteca PIL. El algoritmo depura automáticamente cualquier archivo que presente corrupción o extensiones distintas a .jpg, .jpeg y .png. Seguidamente, los tensores de entrada se reajustan al tamaño típico de la arquitectura objetivo mediante torchvision. Posteriormente, las matrices de intensidad se normalizan al intervalo flotante entre 0 y 1 y se estandarizan por canal utilizando los parámetros ImageNet (0.485, 0.456, 0.406 para media y 0.229, 0.224, 0.225 para desviación estándar).

La separación del dataset en carpetas train, val y test se respeta como operación prioritaria y rigurosa a partir del

sistema de ficheros. Esta segmentación física se ejecuta de forma precedente a cualquier operación de transformación o carga en memoria computacional. Los subconjuntos de validación y evaluación aplican exclusivamente transformaciones de evaluación deterministas sin distorsiones aleatorias. Mediante este protocolo metodológico estricto se garantiza la eliminación completa de contaminación de datos durante las fases de entrenamiento.

El proceso de expansión sintética de datos se restringe exclusivamente al conjunto de entrenamiento en el flujo de trabajo optimizado. Las transformaciones de ampliación en PyTorch incluyen volteos horizontales estocásticos y rotaciones espaciales dentro de un intervalo de $\pm 10^\circ$. Adicionalmente, se incorporan perturbaciones fotométricas dinámicas en el espacio cromático mediante ColorJitter con variaciones de 0.1 en los parámetros de brillo y contraste. Estas modificaciones ejecutadas dinámicamente incrementan la robustez de la arquitectura frente a variaciones visuales sin comprometer la integridad del conjunto de prueba.

El pipeline computacional se ejecuta utilizando la función de pérdida CrossEntropyLoss y el optimizador Adam aprovechando la capacidad de procesamiento de GPU disponible en Google Colab. En la Fase 2 refinada, se implementa precisión mixta automatizada (AMP con GradScaler) para acelerar el rendimiento computacional. La modulación de hiperparámetros se controla dinámicamente mediante el programador ReduceLROnPlateau acompañado de penalización de pesos. Finalmente, se activa un mecanismo de interrupción de convergencia basado en Early Stopping monitorizado sobre val_loss para preservar automáticamente los pesos correspondientes al modelo de mejor desempeño.

4. Resultados

4.1. ResNet50

Entrenamiento desde cero (scratch + normalizado):. La arquitectura ResNet50 fue sometida a entrenamiento desde cero con el pipeline de normalización rigurosa (CenterCrop cuadrado, ecualización de histograma, conversión RGB obligatoria) durante 30 épocas empleando una tasa de aprendizaje constante de 1×10^{-4} , sin expansión sintética de datos ni detención anticipada. Las métricas de desempeño obtenidas en el conjunto de prueba se detallan en la Tabla 4.

Cuadro 4: Métricas de ResNet50 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	97.48 %
Balanced Accuracy	96.93 %
Precisión	98.56 %
Recall (Sensibilidad)	98.05 %
Especificidad	95.82 %
F1-Score	98.31 %
MCC	0.9341
AUC-ROC	0.9980

La estructura residual con 23.5M de parámetros logró una convergencia equilibrada sin indicios de sobreajuste paramétrico. La pérdida de entrenamiento y validación permanecieron próximas a lo largo del entrenamiento, con el modelo óptimo preservado en la época 20 (val_loss de 0.0553). Las curvas de aprendizaje demuestran un descenso paralelo de train_loss y val_loss, corroborando que las conexiones residuales facilitan un aprendizaje efectivo incluso sin inicialización mediante pesos preentrenados.




Figura 6: Curvas de aprendizaje de ResNet50 desde cero con pipeline normalizado.

4.2. EfficientNet-B0

Entrenamiento desde cero (scratch + normalizado):. La arquitectura EfficientNet-B0, caracterizada por su reducida magnitud con solo 4.0M de parámetros, fue entrenada desde cero aplicando el pipeline de normalización rigurosa durante 30 épocas con tasa de aprendizaje constante de 1×10^{-4} . Las métricas de desempeño obtenidas se presentan en la Tabla 5.

Cuadro 5: Métricas de EfficientNet-B0 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	97.00 %
Balanced Accuracy	96.36 %
Precisión	98.30 %
Recall (Sensibilidad)	97.66 %
Especificidad	95.06 %
F1-Score	97.98 %
MCC	0.9215
AUC-ROC	0.9919

A pesar de contener el 95 % menos parámetros en com-

paración con ViT-B/16, EfficientNet-B0 supera al transformador puro por 1.26 puntos porcentuales de accuracy. El modelo alcanzó convergencia acelerada mediante su estrategia de escalamiento compuesto, logrando el val_loss óptimo de 0.0682 en la época 10. Las curvas de aprendizaje exhiben un entrenamiento robusto sin desviación pronunciada entre los conjuntos de entrenamiento y validación. Con una latencia de solo 55.28 ms por lote, EfficientNet-B0 se posiciona como la opción más computacionalmente ágil del estudio, constituyéndose en la alternativa más favorable para ambientes con capacidad computacional restringida.




Figura 7: Curvas de aprendizaje de EfficientNet-B0 desde cero con pipeline normalizado.

4.3. ViT-B/16

Entrenamiento desde cero (scratch + normalizado):. La arquitectura ViT-B/16, que representa el modelo de mayor capacidad en esta investigación (85.8M de parámetros), fue sometida a entrenamiento desde cero con el pipeline de normalización rigurosa durante 30 épocas con tasa de aprendizaje constante de 1×10^{-4} . Las métricas de desempeño resultantes se presentan en la Tabla 6.

Cuadro 6: Métricas de ViT-B/16 entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	95.74 %
Balanced Accuracy	95.53 %
Precisión	97.38 %
Recall (Sensibilidad)	95.84 %
Especificidad	95.22 %
F1-Score	96.61 %
MCC	0.8916
AUC-ROC	0.9892

ViT-B/16 alcanzó la exactitud más baja del estudio (95.74 %), circunstancia notable considerando que triplicaba en parámetros a Swin-T y excedía 21 veces la capacidad de EfficientNet-B0. La carencia de sesgos inductivos convolucionales obliga al modelo a adquirir desde cero la totalidad de relaciones espaciales, resulta ineficiente con un dataset reducido de solo 6893 imágenes. El entrenamiento, no obstante, transcurrió de forma equilibrada: las curvas de aprendizaje (Figura 8) demuestran convergencia coordinada entre entrenamiento y validación, sin la divergencia

característica del sobreajuste observado en configuraciones que aprovechan aprendizaje por transferencia.




Figura 8: Curvas de aprendizaje de ViT-B/16 desde cero con pipeline normalizado.

4.4. Swin Transformer

Entrenamiento desde cero (scratch + normalizado):. Swin-T fue sometida a entrenamiento desde cero con el pipeline de normalización rigurosa durante 30 épocas con tasa de aprendizaje inicial de 1×10^{-4} , posteriormente modulada mediante ReduceLROnPlateau en las fases tardías. Las métricas de desempeño obtenidas se detallan en la Tabla 7.

Cuadro 7: Métricas de Swin-T entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	96.32 %
Balanced Accuracy	96.53 %
Precisión	98.93 %
Recall (Sensibilidad)	96.10 %
Especificidad	96.96 %
F1-Score	97.50 %
MCC	0.9070
AUC-ROC	0.9955

Swin-T superó a ViT-B/16 por 0.58 puntos porcentuales (96.32 % vs. 95.74 %) utilizando 68 % menos parámetros (27.5M vs. 85.8M). El mecanismo de atención local con ventanas desplazadas (7×7) demostró ser más eficiente que la atención global característica de ViT-B/16, permitiendo que el modelo se concentre en regiones anatómicas locales de relevancia clínica. Las curvas de aprendizaje (Figura 9) corroboran un entrenamiento equilibrado carente de sobreajuste, con el modelo óptimo registrado en la época 29 (val_loss de 0.0583).




Figura 9: Curvas de aprendizaje de Swin-T desde cero con pipeline normalizado.

4.5. CoAtNet

Entrenamiento desde cero (scratch + normalizado):. CoAtNet, la arquitectura híbrida que integra capas convolucionales MBConv con módulos de atención Transformer, fue entrenada desde cero con el pipeline de normalización rigurosa durante 30 épocas. Las métricas de desempeño obtenidas se presentan en la Tabla 8.

Cuadro 8: Métricas de CoAtNet entrenado desde cero con pipeline normalizado.

Métrica	Valor
Accuracy	98.35 %
Balanced Accuracy	98.27 %
Precisión	99.34 %
Recall (Sensibilidad)	98.44 %
Especificidad	98.10 %
F1-Score	98.89 %
MCC	0.9572
AUC-ROC	0.9952

CoAtNet manifestó el rendimiento superior del estudio con 98.35 % de accuracy, excediendo a ViT-B/16 por 2.61 puntos porcentuales con 69 % menos parámetros (26.7M vs. 85.8M). La sinergia de convoluciones iniciales —que proporcionan sesgo inductivo de localidad— con atención global en etapas avanzadas generó el equilibrio óptimo entre capacidad representativa y eficiencia operacional. Las curvas de aprendizaje documentan una convergencia excepcionalmente rápida: en la época 3 el modelo ya superaba 96.62 % de exactitud en validación. El entrenamiento fue el más equilibrado de todas las arquitecturas evaluadas, con una diferencia train/val de solo 0.0000 en la época óptima (época 14, val_loss de 0.0389), evidenciando ausencia total de sobreajuste paramétrico.




Figura 10: Curvas de aprendizaje de CoAtNet desde cero con pipeline normalizado.

4.6. Analisis Comparativo

La Tabla 9 presenta un análisis contrastivo de las cinco arquitecturas evaluadas. La totalidad de los modelos fueron entrenados desde cero (sin pesos iniciales de ImageNet) utilizando un pipeline de normalización rigurosa (Center-Crop cuadrado, conversión RGB forzada y ecualización de histograma), lo que asegura una comparación equitativa al suprimir los artefactos estadísticos del dataset identificados durante el análisis exploratorio.

CoAtNet exhibió el rendimiento general superior con 98.35 % de accuracy, un MCC de 0.9572 y únicamente 26.7M de parámetros, aprovechando la sinergia entre capas convolucionales y mecanismos de atención Transformer. ResNet50 (97.48 %) y EfficientNet-B0 (97.00 %) corroboraron que las arquitecturas estrictamente convolucionales proporcionan un desempeño competitivo incluso partiendo de cero, con la ventaja adicional de inferencia rápida (101.9 ms y 55.3 ms por lote respectivamente). Swin-T (96.32 %) superó a ViT-B/16 (95.74 %) gracias a su mecanismo de atención local con ventanas desplazables, confirmando que limitar la atención a regiones anatómicamente significativas resulta más eficaz que la atención global sin restricciones. ViT-B/16, pese a disponer de la mayor capacidad paramétrica del estudio (85.8M de parámetros), exhibió el rendimiento más bajo, evidenciando que la abundancia de parámetros no compensa la carencia de sesgos inductivos en contextos de volumen de datos limitado.

Cuadro 9: Comparacion de resultados. Todos los modelos entrenados desde cero con pipeline de normalizacion estricta (scratch + normalizado).

Metrica	ResNet50	ENet-B0	ViT-B/16	Swin-T	CoAtNet
Accuracy (%)	97.48	97.00	95.74	96.32	98.35
F1-Score (%)	98.31	97.98	96.61	97.50	98.89
MCC	0.9341	0.9215	0.8916	0.9070	0.9572
AUC-ROC	0.9980	0.9919	0.9892	0.9955	0.9952
Parametros (M)	23.5	4.0	85.8	27.5	26.7
Inferencia (ms)	101.9	55.3	205.5	118.6	137.2

Desde la perspectiva de eficiencia operacional, EfficientNet-B0 se destaca por su velocidad de inferencia de solo 55.3 ms y 4.0M de parámetros, siendo 3.7 veces más ágil que ViT-B/16 al utilizar únicamente el 4.7 % de sus parámetros. CoAtNet logra la mejor combinación de exactitud y parsimonia: supera a ResNet50 en accuracy (+0.87 pp) con solo 3.2M de parámetros adicionales. ViT-B/16, dotado de 85.8M de parámetros, manifiesta la inferencia más lenta (205.5 ms) y la exactitud más baja, confirmando que las arquitecturas dotadas de sesgos convolucionales o mecanismos locales de atención resultan más apropiadas para la categorización de neoplasias cerebrales en datasets de tamaño moderado.

4.7. Analisis de Artefactos del Dataset

Un descubrimiento significativo de esta investigación fue la identificación de patrones sistemáticos en el dataset original que inflaban artificialmente las métricas de desempeño. Las imágenes de la clase “yes” (tumor) provenían predominantemente de fuentes con resolución 512×512 y canal de escala de grises, mientras que las de la clase “no” (sano) exhibían resoluciones significativamente menores (mediana 228×242) y formato RGB. Estas disparidades permitían a un clasificador logístico fundamentado exclusivamente en estadísticas de píxeles (sin acceso al contenido visual real) lograr un 83.5 % de accuracy. Luego de aplicar el pipeline de normalización (CenterCrop, ecualización e conversión RGB forzada), el clasificador ciego descendió a 47.5 %

—por debajo del nivel de azar—, validando así la eliminación efectiva de los sesgos. Las métricas reportadas en este estudio reflejan por tanto la capacidad diagnóstica genuina de los modelos sin aprovechamiento de atajos estadísticos espurios.

5. Discusion

Analisis de Sesgo Inductivo en Arquitecturas de Deep Learning: Los hallazgos derivados de condiciones rigurosas —todos los modelos entrenados desde cero con el mismo pipeline de normalización— revelan una jerarquía clara determinada por la presencia de sesgos inductivos convolucionales. CoAtNet (98.35 %), que sintetiza etapas convolucionales MBConv con mecanismos Transformer, encabeza la clasificación al beneficiarse de las convoluciones en las capas tempranas para la extracción de características locales, en tanto que la atención en capas profundas captura dependencias de alcance extenso. ResNet50 (97.48 %) y EfficientNet-B0 (97.00 %), arquitecturas estrictamente convolucionales, ocupan posiciones subsecuentes, demostrando que décadas de refinamiento en el diseño de CNN generan modelos altamente competentes incluso sin aprendizaje por transferencia.

En el extremo opuesto, ViT-B/16 (95.74 %) logra el peor rendimiento pese a disponer de 85.8M de parámetros —3.2 veces más que CoAtNet y 21 veces más que EfficientNet-B0—. La atención global, que permite a cada parche de imagen relacionarse con la totalidad de regiones restantes, se convierte en una desventaja cuando el volumen de datos es limitado: el modelo debe aprender desde cero que píxeles adyacentes están correlacionados (localidad) y que un mismo patrón puede manifestarse en diversas posiciones (equivarianza traslacional), conocimientos que las CNN incorporan estructuralmente. Swin-T (96.32 %), con atención restringida a ventanas locales de 7×7 , mitiga parcialmente esta deficiencia, superando a ViT-B/16 por 0.58 puntos porcentuales con 68 % menos parámetros.

Implicaciones para el Diseno de Sistemas de Diagnostico Asistido: La discrepancia de 2.61 puntos porcentuales entre CoAtNet (98.35 %) y ViT-B/16 (95.74 %) posee implicaciones clínicas significativas: en un conjunto de prueba de 1033 imágenes, CoAtNet cometió aproximadamente 17 errores frente a los 44 perpetrados por ViT-B/16. Para un sistema de asistencia diagnóstica, esta reducción de errores puede traducirse en menos falsos positivos (sujetos sanos referidos innecesariamente) y menos falsos negativos (neoplasias no identificadas).

EfficientNet-B0 merece mención especial: con solo 4.0M de parámetros y 55.3 ms de latencia, alcanza 97.00 % de accuracy, excediendo a ViT-B/16 por 1.26 puntos porcentuales utilizando únicamente el 4.7 % de sus parámetros. Esta característica la posiciona como la opción ideal para despliegue en contextos con recursos limitados, donde la

velocidad de inferencia y el consumo de memoria resultan críticos.

Limitaciones del Estudio: Aunque el pipeline de normalización eliminó los artefactos estadísticos más evidentes (diferencia de resolución, modo de color y distribución de brillo entre categorías), la evaluación se limitó a un único dataset de origen público (Kaggle). La validación externa mediante imágenes de otros centros hospitalarios o protocolos de adquisición constituye un paso fundamental para confirmar la capacidad de generalización de los resultados. Asimismo, el entrenamiento desde cero con 30 épocas fijas representa una configuración basal; la incorporación de técnicas adicionales tales como expansión sintética más agresiva o aprendizaje autosupervisado podría mejorar el rendimiento, aunque introduciría nuevas variables confusoras en la comparación.

6. Conclusiones

Se llevó a cabo la evaluación de cinco arquitecturas de aprendizaje profundo (ResNet50, EfficientNet-B0, ViT-B/16, Swin-T y CoAtNet) dedicadas a la categorización binaria de neoplasias cerebrales en representaciones de resonancia magnética. La totalidad de los modelos fueron entrenados desde cero implementando un pipeline de normalización riguroso diseñado para suprimir artefactos estadísticos del dataset que inflaban artificialmente las métricas. Los hallazgos primordiales se pueden sintetizar como sigue:

CoAtNet, la arquitectura que integra características CNN-Transformer, alcanzó el rendimiento global más elevado exhibiendo 98.35 % de accuracy (MCC de 0.9572), demostrando que la síntesis de sesgos convolucionales locales con atención global en capas profundas suministra el equilibrio óptimo para este dominio de aplicación. Las arquitecturas puramente convolucionales —ResNet50 (97.48 %) y EfficientNet-B0 (97.00 %)— brindaron rendimiento competitivo con menor costo operacional, siendo EfficientNet-B0 particularmente eficiente con apenas 4.0M de parámetros y 55.3 ms por lote. Swin-T (96.32 %) superó a ViT-B/16 (95.74 %) mediante su mecanismo de atención local con ventanas desplazadas, corroborando que limitar el alcance de la atención a regiones anatómicamente pertinentes resulta más efectivo que la atención global cuando los datos disponibles son limitados. ViT-B/16, a pesar de constituir el modelo de mayor capacidad paramétrica (85.8M de parámetros), manifestó el rendimiento más bajo, evidenciando que los transformers puros demandan volúmenes masivos de datos para compensar su carencia de sesgos inductivos.

Un hallazgo metodológico de importancia radica en la identificación de artefactos sistemáticos en el dataset original (disparidades de resolución, modo de color y distribución de intensidad entre categorías) que permitían a un clasificador superficial lograr 83.5 % de accuracy sin acceso

al contenido visual real. La aplicación del pipeline de normalización (CenterCrop cuadrado, ecualización de histograma y conversión RGB obligatoria) redujo este baseline ingenuo a 47.5 %, garantizando que las métricas reportadas reflejan capacidad diagnóstica genuina.

Los resultados corroboran que, en contextos con volumen de datos limitado característicos de aplicaciones médicas, la arquitectura del modelo (sesgos inductivos) es más determinante que la abundancia de parámetros. Las arquitecturas dotadas de componentes convolucionales o mecanismos de atención local demuestran rendimiento superior a los transformers puros con atención global, posicionándose como las opciones más apropiadas para el desarrollo de sistemas de asistencia diagnóstica mediante inteligencia artificial en entornos clínicos con recursos computacionales acotados.

7. Limitaciones

Aunque el estudio presenta resultados positivos, existen limitaciones que merecen consideración. El dataset utilizado, pese a ser representativo, procede de una única fuente pública, circunstancia que puede comprometer la generalización hacia otros centros médicos equipados con instrumentos y protocolos de adquisición distintos. No se realizó validación externa en cohortes independientes ni se contrastó el rendimiento en conjuntos de datos multicéntricos. Además, todas las arquitecturas fueron entrenadas desde cero sin aprovechamiento de aprendizaje por transferencia, incrementando los tiempos de convergencia en relación con enfoques que utilizan modelos preentrenados. Finalmente, la investigación se restringió a la categorización de cuatro tipos tumorales; la detección temprana de neoplasias de bajo grado y la delineación precisa de márgenes tumorales escapan al alcance de este trabajo.

8. Trabajos Futuros

Como líneas de investigación futura se propone la validación de los modelos en conjuntos de datos multicéntricos (tales como BraTS o TCGA) para evaluar su capacidad de generalización en contextos clínicos auténticos. La exploración de técnicas de aprendizaje por transferencia con arquitecturas preentrenadas en ImageNet podría acelerar los procesos de entrenamiento e incrementar el rendimiento, particularmente en arquitecturas transformer que demandan elevada capacidad paramétrica. Asimismo, resultaría relevante la integración de mecanismos de interpretabilidad (por ejemplo, Grad-CAM, visualización de mapas de atención) para fortalecer la confiabilidad clínica de las predicciones. Finalmente, se recomienda la extensión del estudio hacia tareas de segmentación de neoplasias y categorización multiclase considerando grados de malignidad.

Referencias

- [1] C. Ding, Y. Wu, X. Chen, Y. Chen, Z. Wu, Z. Lin, D. Kang, W. Fang, F. Chen, Global, regional, and national burden and attributable risk factors of neurological disorders: The global burden of disease study 1990–2019, *Frontiers in Public Health* 10 (11 2022). doi:10.3389/fpubh.2022.952161.
- [2] I. Mavroudis, D. Kazis, F. Z. Kamal, I.-L. Gurzu, A. Ciobica, M. Pădurariu, B. Novac, A. Iordache, Understanding functional neurological disorder: Recent insights and diagnostic challenges, *International Journal of Molecular Sciences* 25 (2024) 4470. doi:10.3390/ijms25084470.
- [3] S. A. Finkelstein, C. Diamond, A. Carson, J. Stone, Incidence and prevalence of functional neurological disorder: a systematic review, *Journal of Neurology, Neurosurgery & Psychiatry* 96 (2025) 383–395. doi:10.1136/jnnp-2024-334767.
- [4] M. Pichaiavel, G. Anbumani, P. Theivendren, M. Gopal, An Overview of Brain Tumor, *IntechOpen*, 2022. doi:10.5772/intechopen.100806.
- [5] L. R. Schaff, I. K. Mellinghoff, Glioblastoma and other primary brain malignancies in adults, *JAMA* 329 (2023) 574. doi:10.1001/jama.2023.0023.
- [6] G. D. Barkade, P. S. Bhosale, S. K. Shirsath, Overview of brain cancer, its symptoms, diagnosis and treatment, *IP International Journal of Comprehensive and Advanced Pharmacology* 8 (2023) 159–164. doi:10.18231/j.ijcaap.2023.027.
- [7] V. Essianda, A. D. Indrasari, P. Widyastuti, T. Syahla, R. Rohadi, Brain tumor : Molecular biology, pathophysiology, and clinical symptoms, *Jurnal Biologi Tropis* 23 (2023) 260–269. doi:10.29303/jbt.v23i4.5585.
- [8] M. Martucci, R. Russo, F. Schimperna, G. D'Apollito, M. Panfili, A. Grimaldi, A. Perna, A. M. Ferranti, G. Varcasia, C. Giordano, S. Gaudino, Magnetic resonance imaging of primary adult brain tumors: State of the art and future perspectives, *Biomedicine* 11 (2023) 364. doi:10.3390/biomedicines11020364.
- [9] Y. Wang, Z. Hu, H. Wang, The clinical implications and interpretability of computational medical imaging (radiomics) in brain tumors, *Insights into Imaging* 16 (2025) 77. doi:10.1186/s13244-025-01950-6.
- [10] R. M. Nikam, X. Yue, G. Kaur, V. Kandula, A. Khair, H. H. KecsKemethy, L. W. Averill, S. A. Langhans, Advanced neuroimaging approaches to pediatric brain tumors, *Cancers* 14 (2022) 3401. doi:10.3390/cancers14143401.
- [11] Y. M. A. Mohammed, S. E. Garouani, I. Jellouli, A survey of methods for brain tumor segmentation-based mri images, *Journal of Computational Design and Engineering* 10 (2023) 266–293. doi:10.1093/jcde/qwac141.
- [12] A. A. A. Rabah, M. A. Binmhusien, M. H. Alotaibi, B. A. Almalki, Magnetic resonance imaging (mri): Principles, applications, and clinical utility, *Journal of Advances and Scholarly Researches in Allied Education* 21 (2024) 83–85. doi:10.29070/qvz4sm62.
- [13] D. M. Taha, A. T. Abdulqader, A. M. H. Al-Khawaja, H. A. Mousa, Review article about magnetic resonance imaging (mri), *European Journal of Theoretical and Applied Sciences* 2 (2024) 530–535. doi:10.59324/ejtas.2024.2(5).51.
- [14] S. Hussain, I. Mubeen, N. Ullah, S. S. U. D. Shah, B. A. Khan, M. Zahoor, R. Ullah, F. A. Khan, M. A. Sultan, Modern diagnostic imaging technique applications and risk factors in the medical field: A review, *BioMed Research International* 2022 (1 2022). doi:10.1155/2022/5164970.
- [15] M. H. Alsaedi, F. M. H. Joman, A. F. M. Alraddadi, H. N. B. S. Alharbi, M. A. R. A. Amry, H. K. Alazhri, M. S. Almaghamisi, A. A. Alqubali, W. A. H. Hwsawy, F. S. Mousa, Advancements in magnetic resonance imaging: A systematic review of emerging technologies and clinical applications, *Journal of Ecocumanism* 3 (2024) 1798–1803. doi:10.62754/joe.v3i8.4873.
- [16] A. B. Abdusalomov, M. Mukhiddinov, T. K. Whangbo, Brain tumor detection based on deep learning approaches and magnetic resonance imaging, *Cancers* 15 (2023) 4172. doi:10.3390/cancers15164172.
- [17] T. A. Soomro, L. Zheng, A. J. Afifi, A. Ali, S. Soomro, M. Yin, J. Gao, Image segmentation for mr brain tumor detection using machine learning: A review, *IEEE Reviews in Biomedical Engineering* 16 (2023) 70–90. doi:10.1109/RBME.2022.3185292.
- [18] S. Anantharajan, S. Gunasekaran, T. Subramanian, V. R. Mri brain tumor detection using deep learning and machine learning approaches, *Measurement: Sensors* 31 (2024) 101026. doi:10.1016/j.measen.2024.101026.
- [19] M. S. I. Khan, A. Rahman, T. Debnath, M. R. Karim, M. K. Nasir, S. S. Band, A. Mosavi, I. Dehzangi, Accurate brain tumor detection using deep convolutional neural network, *Computational and Structural Biotechnology Journal* 20 (2022) 4733–4745. doi:10.1016/j.csbj.2022.08.039.
- [20] M. I. Mahmud, M. Mamun, A. Abdelgawad, A deep analysis of brain tumor detection from mr images using deep learning networks, *Algorithms* 16 (2023) 176. doi:10.3390/a16040176.
- [21] F. J. Dorfner, J. B. Patel, J. Kalpathy-Cramer, E. R. Gerstner, C. P. Bridge, A review of deep learning for brain tumor analysis in mri, *npj Precision Oncology* 9 (2025) 2. doi:10.1038/s41698-024-00789-2.
- [22] R. Disci, F. Gurcan, A. Soylu, Advanced brain tumor classification in mr images using transfer learning and pre-trained deep cnn models, *Cancers* 17 (2025) 121. doi:10.3390/cancers17010121.
- [23] B. B. Vimala, S. Srinivasan, S. K. Mathivanan, Mahalakshmi, P. Jayagopal, G. T. Dalu, Detection and classification of brain tumor using hybrid deep learning models, *Scientific Reports* 13 (2023) 23029. doi:10.1038/s41598-023-50505-6.
- [24] R. D. Prayogo, N. Hamid, H. Nambo, Hybrid cnn-based transfer learning enhances brain tumor classification on mri images, *IEEE Access* 13 (2025) 116654–116668. doi:10.1109/ACCESS.2025.3584376.
- [25] C. Mitra, M. Ikbali, F. Parvin, M. M. Rahman, D. Asadujjaman, Transfer learning based multiclass brain tumor classification using mri data, in: 2025 International Conference on Quantum Photonics, Artificial Intelligence, and Networking (QPAIN), IEEE, 2025, pp. 1–6. doi:10.1109/QPAIN66474.2025.11172074.
- [26] S. Panigrahi, D. R. D. Adhikary, B. K. Pattanayak, B. B. Dash, U. C. De, S. S. Patra, Interpretable multi-class brain mri tumor classification with vit-b16 transformer, in: 2025 IEEE 4th International Conference for Advancement in Technology (ICONAT), IEEE, 2025, pp. 1–5. doi:10.1109/ICONAT66879.2025.11362544.
- [27] A. Jain, A. Mishra, G. Bethany, M. Gupta, A. Poulse, Advanced brain tumor classification from mri images with vision and swin transformer models, in: 2025 Emerging Technologies for Intelligent Systems (ETIS), IEEE, 2025, pp. 1–5. doi:10.1109/ETIS64005.2025.10961204.
- [28] M. Aloraini, A. Khan, S. Aladhadh, S. Habib, M. F. Alsharekh, M. Islam, Combining the transformer and convolution for effective brain tumor classification using mri images, *Applied Sciences* 13 (2023) 3680. doi:10.3390/app13063680.
- [29] S. Tabatabaei, K. Rezaee, M. Zhu, Attention transformer mechanism and fusion-based deep learning architecture for mri brain tumor classification system, *Biomedical Signal Processing and Control* 86 (2023) 105119. doi:10.1016/j.bspc.2023.105119.
- [30] C. Lv, X.-J. Shu, Q. Liang, J. Qiu, Z.-C. Xiong, J. bo Ye, S. bo Li, C. Q. Liu, J. Z. Niu, S.-B. Chen, H. Rao, Brain-tumnet: multi-task deep learning framework for brain tumor segmentation and classification using adaptive masked transformers, *Frontiers in Oncology* 15 (5 2025). doi:10.3389/fonc.2025.1585891.
- [31] K. Dang, T. Vo, L. Ngo, H. Ha, A deep learning framework integrating mri image preprocessing methods for brain tumor segmentation and classification, *IBRO Neuroscience Reports* 13 (2022) 523–532. doi:10.1016/j.ibneur.2022.10.014.
- [32] N. Kühl, M. Schemmer, M. Goutier, G. Satzger, Artificial intelligence and machine learning, *Electronic Markets* 32 (4) (2022) 2235–2244. doi:10.1007/s12525-022-00598-0.
- [33] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie,

- L. Farhan, Review of deep learning: Concepts, cnn architectures, challenges, applications, future directions, *Journal of Big Data* 8 (2021) 53. [doi:10.1186/s40537-021-00444-8](https://doi.org/10.1186/s40537-021-00444-8).
- [34] M. Li, Y. Jiang, Y. Zhang, H. Zhu, Medical image analysis using deep learning algorithms, *Frontiers in Public Health* 11 (2023) 1273253. [doi:10.3389/fpubh.2023.1273253](https://doi.org/10.3389/fpubh.2023.1273253).
- [35] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, M. Parmar, A review of convolutional neural networks in computer vision, *Artificial Intelligence Review* 57 (2024). [doi:10.1007/s10462-024-10721-6](https://doi.org/10.1007/s10462-024-10721-6).
- [36] Y. Wang, Y. Deng, Y. Zheng, P. Chattopadhyay, L. Wang, Vision transformers for image classification: A comparative survey, *Technologies* 13 (1) (2025) 32. [doi:10.3390/technologies13010032](https://doi.org/10.3390/technologies13010032).
- [37] A. Khan, Z. Rauf, A. Sohail, A. R. Khan, H. Asif, A. Asif, U. Farooq, A survey of the vision transformers and their cnn-transformer based variants, *Artificial Intelligence Review* 56 (2023) 2917–2970. [doi:10.1007/s10462-023-10595-0](https://doi.org/10.1007/s10462-023-10595-0).
- [38] A. Salehi, S. Khan, G. Gupta, B. Alabduallah, A. Almjally, H. Alsolai, T. Siddiqui, A. Mellit, A study of cnn and transfer learning in medical imaging: Advantages, challenges, future scope, *Sustainability* 15 (7) (2023) 5930. [doi:10.3390/su15075930](https://doi.org/10.3390/su15075930).
- [39] O. Rainio, J. Teuho, R. Klén, Evaluation metrics and statistical tests for machine learning, *Scientific Reports* 14 (2024). [doi:10.1038/s41598-024-56706-x](https://doi.org/10.1038/s41598-024-56706-x).
- [40] K. Gao, S. Tasneem, T. M. Khoshgoftaar, Medical imaging with deep learning: A comparison of cnn and transformer models, in: 2025 International Conference on Machine Learning and Applications (ICMLA), 2025, pp. 523–530. [doi:10.1109/ICMLA66185.2025.00077](https://doi.org/10.1109/ICMLA66185.2025.00077).
- [41] M. Rana, M. Bhushan, Machine learning and deep learning approach for medical image analysis: diagnosis to detection, *Multimedia Tools and Applications* 82 (2022) 26731–26769. [doi:10.1007/s11042-022-14305-w](https://doi.org/10.1007/s11042-022-14305-w).
- [42] M. Puttagunta, S. Ravi, Medical image analysis based on deep learning approach, *Multimedia Tools and Applications* 80 (2021) 24365–24398. [doi:10.1007/s11042-021-10707-4](https://doi.org/10.1007/s11042-021-10707-4).
- [43] M. Beirović, A. Kurtović, N. Smajlović, M. Kapo, A. Akagić, Performance comparison of medical image classification systems using tensorflow keras, pytorch, and jax, *arXiv* (2025). [doi:10.48550/arXiv.2507.14587](https://doi.org/10.48550/arXiv.2507.14587). URL <https://arxiv.org/abs/2507.14587>
- [44] H. Laçi, K. Sevrani, S. Iqbal, Deep learning approaches for classification tasks in medical x-ray, mri, and ultrasound images: a scoping review, *BMC Medical Imaging* 25 (2025) 209. [doi:10.1186/s12880-025-01701-5](https://doi.org/10.1186/s12880-025-01701-5).
- [45] Shashin, Brain tumor mri datasets, Kaggle (2024). URL <https://www.kaggle.com/datasets/luluw8071/brain-tumor-mri-datasets>